



Explainable Artificial Intelligence

(XAI)





المدرسة الوطنية للذكاء الاصطناعي والرقمنة - بركان

ÉCOLE NATIONALE DE L'INTELLIGENCE ARTIFICIELLE ET DU DIGITAL - BERKANE

«Национальная школа искусственного интеллекта и цифровизации» - БРКАН

Chapitre 1





Introduction: Intelligence Artificielle

- L'intelligence artificielle: un domaine de l'informatique qui utilise des algorithmes, des données et des capacités de calcul afin de créer des systèmes capables d'exécuter des tâches nécessitant généralement l'intelligence humaine.
- L'objectif de l'IA est de permettre aux machines de raisonner de manière similaire aux humains, de traiter de grandes quantités de données et d'accomplir des actions considérées comme "intelligentes".
- L'IA permet aux machines d'accomplir des tâches semblables à celles des humains.



Introduction: Intelligence Artificielle

La **peur** de l'inconnu...!



QUESTIONS QUI NOUS
INTÉRESSENT

- Pourquoi as-tu fait ça ?
- Pourquoi pas autre chose ?
- Quand réussis-tu ?
- Quand échoues-tu ?
- Quand puis-je te faire confiance ?
- Comment corriger une erreur ?

- IA « **boîte noire** » : aucune compréhension du processus de prise de décision.






Introduction

Catégories de modèles en apprentissage automatique (ML)

Modèles boîte blanche (White Box Models)


- ☐ Faciles à interpréter.
- ☐ Parfois incapables d'apprendre efficacement les motifs présents dans les données (faible précision) en raison de leur simplicité.



Modèles boîte noire (Black Box Models)

- ☐ Difficiles (voire impossibles) à interpréter.
- ☐ Généralement plus puissants et plus performants que les modèles boîte blanche, par exemple les réseaux neuronaux.

Motivation




« l'IA explicable (XAI) devient indispensable. Elle permet **d'ouvrir la boîte noire**, de comprendre le raisonnement de l'IA, et de restaurer la confiance. »



Introduction: Intelligence Artificielle

Passer des modèles de **boîte noire** aux modèles de **boîte blanche** XAI



- IA « **explicable** » : comprendre le fonctionnement interne du modèle.








IA Explicable : Définition


- L'**intelligence artificielle explicable (XAI)** désigne l'ensemble des méthodes et techniques qui permettent de rendre les décisions des modèles d'IA compréhensibles et interprétables par les humains.
=> comprendre comment et pourquoi un modèle d'IA prend une décision.
- L'**XAI** regroupe les approches visant à expliquer le fonctionnement interne d'un modèle d'IA ou à justifier ses prédictions, afin que ses utilisateurs puissent **comprendre, faire confiance, valider et superviser ses résultats**.
- Il s'agit d'une approche proposée pour favoriser une intelligence artificielle plus transparente et, par conséquent, éviter de limiter l'adoption de l'IA dans des domaines critiques.





IA Explicable : Définition


- L'XAI regroupe des techniques qui permettent :
 - d'identifier les facteurs ayant influencé une décision,
 - de comprendre le comportement d'un modèle,
 - d'évaluer la validité de ses résultats.
- Elle favorise la transparence, la confiance et la responsabilité, et la possibilité d'audit des systèmes d'IA.



Pourquoi comprendre les modèles ?





L'apprentissage automatique est
PARTOUT !!



Customers who have shown an interest in point-and-shoot cameras might like to see this week's bestselling models.



Canon PowerShot A495 10.0 MP Digital Camera with 3.3x Optical Zoom and 2.5-Inch LCD (Blue)
Canon PowerShot A3000IS 10 MP Digital Camera with 4x Optical Image Stabilized Zoom and 2.7-Inch LCD
Canon PowerShot ELPH 300 HS 12 MP CMOS Digital Camera with Full 1080p HD Video (Black)
Canon PowerShot S95 10 MP Digital Camera with 3.8x Wide Angle Optical Image Stabilized Zoom and 3.0-Inch inch LCD



: Pourquoi comprendre les modèles ?

La compréhension du modèle
facilite le débogage.

Input



Predictive
Model



Model Understanding



Prediction = Husky sibérien


Ce modèle utilise
des caractéristiques
incorrectes pour
effectuer cette
prédiction ! Je vais
corriger le modèle.




: Pourquoi comprendre les modèles ?

La compréhension des modèles facilite la détection des biais.

Defendant Details




Predictive Model




Cette prédiction est biaisée. La race et le sexe sont utilisés pour faire cette prédiction !



: Pourquoi comprendre les modèles ?



Pourquoi comprendre les modèles ?





Pourquoi comprendre les modèles ?

Utilité


- ☐ Débogage
- ☐ Détection des biais
- ☐ Recours
- ☐ Quand et dans quelle mesure faire confiance aux prévisions des modèles
- ☐ Évaluer les modèles afin de vérifier leur aptitude à être déployés

Parties prenantes (Stakeholders)

- ☐ Utilisateurs finaux (par exemple, demandeurs de prêt)
- ☐ Décideurs (par exemple, médecins, juges)
- ☐ Organismes de réglementation (par exemple, FDA, Commission européenne)
- ☐ Chercheurs et ingénieurs





IA Explicable: Les Concepts Clés de l'XAI





IA Explicable : Les piliers de l'XAI



XAI : Transparence

Transparence (Transparency)

- La **transparence** désigne le degré auquel le fonctionnement interne d'un modèle peut être directement compris par un humain.
- Implique que l'architecture, les paramètres et le processus de décision soient visibles et compréhensibles sans nécessiter de techniques supplémentaires d'explication.

=> Comprendre directement le fonctionnement interne du modèle

Les modèles simples (ex. : régression linéaire, arbres de décision) sont dits transparents.






XAI : Intelligibilité

- **Intelligibilité (Intelligibility)**

- L'**intelligibilité** caractérise la facilité avec laquelle un humain peut saisir la logique ou les principes haut du modèle.
- Mesure dans quelle mesure les informations fournies sur le modèle peuvent être comprises globalement, même si l'intégralité des mécanismes internes ne l'est pas.


=> Comprendre globalement comment le modèle fonctionne

- **Interprétabilité (Interpretability)**
- **Explicabilité (Explainability)**



XAI : Interprétabilité Vs Explicabilité

Interprétabilité : degré selon lequel les informations fournies peuvent être comprises par le public ciblé en fonction de ses connaissances dans le domaine.



Sont-ils deux mots identiques ?
Sont-ils interchangeables ?

Explicabilité: fournir des informations à un public ciblé afin de répondre à un besoin.






XAI : Interprétabilité

- **Interprétabilité (Interpretability)**

- L'interprétabilité correspond à la capacité d'un humain à **comprendre la relation entre les variables d'entrée et la sortie du modèle.**
- Indique à quel point on peut déterminer pourquoi le modèle a produit un résultat spécifique à partir de ses entrées.

=> Comprendre comment les entrées influencent la sortie

Exemple : savoir qu'une hausse du revenu augmente la probabilité d'obtenir un crédit.






XAI : Explicabilité

- **Explicabilité (Explainability)**

- L'explicabilité désigne la capacité à fournir **une explication claire et compréhensible** des décisions du modèle, souvent au moyen de techniques externes.
- L'explicabilité vise à traduire les opérations internes, même complexes, en justification interprétable par l'utilisateur.

⇒ Justifier les décisions du modèle (souvent via outils externes)

Exemple : méthodes comme LIME ou SHAP expliquent les décisions de modèles boîte noire comme les réseaux neuronaux.



XAI : Robustesse

- **Robustesse (Robustness):**

- La robustesse se réfère à la capacité d'un modèle explicatif à fournir des **explications fiables, cohérentes et stables** lorsque les données d'entrée subissent de légères perturbations.
- Un système d'explication robuste produit des justifications qui ne fluctuent pas de manière excessive sous des variations mineures, et demeure crédible même dans des conditions d'incertitude.
- En XAI, la robustesse désigne **la stabilité et la fiabilité des explications face à des modifications limitées des données** ou du contexte d'analyse.

=> **Garantir la stabilité et la fiabilité des explications**

Exemple : Si une explication change radicalement pour des perturbations minimales, elle n'est pas robuste.



XAI un pont

L'XAI agit comme un pont entre ces modèles complexes et les utilisateurs finaux, à travers plusieurs types d'explications :

1. Visual Analytics :



Utilise des représentations graphiques, des heatmaps, des graphiques interactifs pour montrer visuellement quelles features ont influencé la décision.

2. Interactive ML :

Permet aux utilisateurs d'interagir avec le modèle, de modifier des paramètres et de voir en temps réel comment la décision change.

3. Q/A Dialog (Dialogue Questions/Réponses) :


Système où l'utilisateur peut poser des questions naturelles au modèle ("Pourquoi as-tu pris cette décision ?") et obtenir des réponses compréhensibles.



XAI: Les objectifs de l'XAI

L'IA Explicable (XAI) créera une suite de techniques d'apprentissage automatique qui :

- ❑ Produisent des modèles plus explicables, tout en maintenant un niveau **élevé de performance** d'apprentissage (Précision de la prédiction).
- ❑ Permettent aux utilisateurs humains de **comprendre, d'accorder une confiance** appropriée et de **gérer efficacement** la nouvelle génération de partenaires dotés d'intelligence artificielle.



XAI : ce que nous essayons de faire

Aujourd'hui
XAI OFF




- Pourquoi as-tu fait ça ?
- Pourquoi pas autre chose ?
- Quand réussis-tu ?
- Quand échoues-tu ?
- Quand puis-je te faire confiance ?
- Comment corriger une erreur ?



Training
Data

Learning
Process



Learned Function

This is a cat
($p = .93$)

Output



User with a Task




XAI: ce que nous essayons de faire

Demain
XAI ON




- Je comprends pourquoi
- Je comprends pourquoi pas
- Je sais quand tu réussiras
- Je sais quand tu échoueras
- Je sais quand te faire confiance
- Je sais pourquoi tu t'es trompé



Training Data

New Learning Process



This is a cat:

- It has fur, whiskers, and claws.
- It has this feature:




User with a Task

Explainable Model Explanation Interface



XAI: cadre général d'explication



Le système prend en entrée les données de la tâche en cours et formule une recommandation, une décision ou une action.

Le système fournit à l'utilisateur une explication qui justifie sa recommandation, sa décision ou son action.


Decision

L'utilisateur prend une décision basée sur l'explication.










XAI: Pourquoi l'explicabilité : améliorer ML




- Grâce à l'**interprétabilité**, les experts peuvent :
 - **Comprendre** les raisonnements du modèle
 - **Identifier** les patterns problématiques
 - **Détecter** les biais ou les erreurs systématiques



Catégorisation des méthodes en XAI




Taxonomie des methods de XAI




Intrinsic Explanation
(global or local)

Naturellement
interprétables par
conception




Post-hoc
Global Explanation

Utilise des techniques **après**
l'entraînement pour expliquer
le **comportement général** du
modèle.




Post-hoc
Local Explanation

Explique une **décision**
spécifique, une prédiction
individuelle.



Enjeux éthiques et réglementaires en XAI (RGPD, biais, responsabilité)



- ☐ Règlement Général sur la Protection des Données (RGPD).
- ☐ Le RGPD impose aux entreprises de fournir des explications sur leurs modèles d'apprentissage automatique (ML) à leurs clients.
- ☐ L'implication légale d'un diagnostic erroné dans les applications médicales peut être sévère ! (bien sûr, la perte humaine est encore plus triste !)
- ☐ Comment le médecin peut-il faire confiance aux prédictions du modèle d'apprentissage automatique (ML) ?





Enjeux éthiques et réglementaires en XAI (RGPD, biais, responsabilité)

a) RGPD (Règlement Général sur la Protection des Données)

Le RGPD est un cadre juridique européen qui vise à protéger les données personnelles et les droits des individus face aux traitements automatisés, y compris ceux utilisant l'intelligence artificielle.

Enjeux en XAI :

- Les systèmes d'IA doivent être **transparents**, c'est-à-dire capables d'expliquer comment et pourquoi une décision a été prise.
- RGPD prévoit que tout **individu a le droit de ne pas être soumis à une décision entièrement automatisée** sans possibilité d'explication ou de recours.
- **Minimisation et protection des données** : seules les données nécessaires doivent être collectées, stockées et traitées.

Exemple : un modèle de crédit doit pouvoir expliquer à un client pourquoi sa demande a été refusée (variables influentes, seuils, pondérations, etc.).





Enjeux éthiques et réglementaires en XAI (RGPD, biais, responsabilité)

- **b) Biais algorithmiques**

Les **biais** désignent des **distorsions** dans les données ou les modèles entraînant des décisions injustes, discriminatoires ou inéquitables.


- **Types de biais :**

- **Biais de données** : les données d'entraînement reflètent des déséquilibres historiques (ex. : sous-représentation d'un groupe).
- **Biais de conception** : les choix de variables, d'objectifs ou de modèles favorisent certains résultats.
- **Biais d'interprétation** : mauvaise compréhension des explications fournies par le modèle.

- **Enjeux en XAI :**

L'explicabilité permet :

- de **détecter et analyser les biais**, Garantir l'**équité** (fairness) des décisions.
- de **rendre les modèles plus justes et responsables**,
- d'améliorer la **confiance** des utilisateurs dans les décisions de l'IA.





Enjeux éthiques et réglementaires en XAI (RGPD, biais, responsabilité)

C) Responsabilité (Accountability)

La responsabilité concerne la question : « **Qui est responsable lorsqu'un système d'IA commet une erreur ou cause un préjudice ?** »

Enjeux en XAI :

- Les décisions algorithmiques doivent être **traçables** et **justifiables**, afin d'identifier la source d'une erreur.
- Le XAI contribue à la **redevabilité** en fournissant des explications compréhensibles aux décideurs, aux auditeurs et aux utilisateurs.
- Les acteurs impliqués (développeurs, entreprises, institutions) doivent être capables de rendre compte des choix techniques, des données utilisées et des impacts générés.

Exemple : en cas de refus injustifié d'un prêt automatisé, la banque doit pouvoir expliquer la décision et assumer la responsabilité.

