




المدرسة الوطنية للذكاء الاصطناعي والرقمنة - بركان
ÉCOLE NATIONALE DE L'INTELLIGENCE ARTIFICIELLE ET DU DIGITAL - BERKANE
ⵎⵔⵓⵙⵉ ⵙⵓⵎⵓⵔⵉ ⵙⵓⵎⵓⵔⵉ ⵙⵓⵎⵓⵔⵉ ⵙⵓⵎⵓⵔⵉ ⵙⵓⵎⵓⵔⵉ ⵙⵓⵎⵓⵔⵉ - ⵙⵓⵎⵓⵔⵉ

Explainable Artificial Intelligence (XAI)





المدرسة الوطنية للذكاء الاصطناعي والرقمنة - بركان
ÉCOLE NATIONALE DE L'INTELLIGENCE ARTIFICIELLE ET DU DIGITAL - BERKANE
«Искусство. Искусство. Искусство» - БУДУЩЕЕ


Chapitre 2

Modèles Interprétables Intrinsèquement






Positionnement dans le cadre global de la XAI






Positionnement dans le cadre global de la XAI



Définition des Modèles interprétables intrinsèquement

- Les modèles intrinsèquement interprétables sont des modèles dont la structure interne **est conçue, dès l'origine, pour être compréhensible par un humain.**
- Contrairement aux modèles **boîte noire** (deep learning, ensembles complexes), ces modèles permettent :
 - ☐ visualiser directement les relations entre les variables,
 - ☐ justifier intuitivement les prédictions,
 - ☐ d'expliquer globalement leur fonctionnement sans outils externes.

=> Ils offrent une transparence “**native**”, sans recourir à des méthodes post-hoc.






Exemples des Modèles interprétables intrinsèquement

Exemples typiques :

- ☐ Régressions linéaires / logistiques
- ☐ Arbres de décision simples
- ☐ Modèles à règles (Rule-based models)
- ☐ k-NN (proximité naturelle)
- ☐ Modèles additifs généralisés (GAM, Explainable Boosting Machines EBM)






Pourquoi utiliser des modèles intrinsèquement interprétables ?

- **Avantages:**

- ✓ **Transparence totale**
Chaque décision est traçable.
- ✓ **Faciles à valider et auditer**
Importants dans les domaines sensibles : santé, finance, justice.
Idéal pour les audits éthiques, réglementaires (RGPD, IA Act, fairness).
- ✓ **Robustes au surapprentissage dans les petits datasets**
Moins de paramètres → meilleure généralisation.
- ✓ **Compréhension directe par les décideurs**
Non-spécialistes peuvent lire les explications.

- **Limitations:**

- ✗ Moins performants sur les données massives / non structurées.
- ✗ Ne capturent pas toujours les non-linéarités fortes.
- ✗ Peuvent devenir non interprétables si trop complexes (arbres trop profonds, modèles trop de règles).





Modèles intrinsèquement interprétables: Les modèles linéaires

a) Régression linéaire


La régression linéaire est un modèle statistique simple qui permet de représenter la dépendance d'une variable cible **Y** en fonction d'un ensemble de caractéristiques $(x_1 \dots x_k)$ au moyen d'une relation **linéaire** :

$$Y = m_0 + m_1 x_1 + m_2 x_2 + \dots + m_k x_k \quad (2.1)$$

(Équation 2.1) Relation linéaire standard entre une variable cible Y et plusieurs caractéristiques $(x_1 \dots x_k)$

- **Interprétation :**

- Chaque coefficient m_i représente **l'impact direct** de la variable x_i sur la prédiction.
- Le signe indique le sens de l'influence (positif $\rightarrow$ augmente la cible, négatif $\rightarrow$ la diminue).
- Identifier des facteurs les plus influents sur la prédiction.






Modèles intrinsèquement interprétables: Les modèles linéaires

Régression linéaire

Propriété	Évaluation
Complétude	Complétude totale atteinte sans avoir besoin de faire un compromis avec l'interprétabilité, car il s'agit d'un modèle intrinsèquement explicable.
Pouvoir expressif	Les coefficients de corrélation offrent une interprétation directe des poids de la régression linéaire.
Translucidité	Élevée : on peut examiner directement les éléments internes du modèle pour produire des explications.
Portabilité	Faible : les explications dépendent spécifiquement du fonctionnement interne de la régression linéaire.
Complexité algorithmique	Faible : aucune méthode complexe n'est nécessaire pour générer les explications.
Compréhensibilité	Bon niveau d'explications compréhensibles par les humains, permettant de renforcer la confiance du producteur de vin.





Modèles intrinsèquement interprétables: Les modèles linéaires

b) Régression logistique


La régression logistique est une extension de la régression linéaire conçue pour traiter les problèmes de classification, en particulier la classification binaire. afin de contraindre la sortie à être comprise entre 0 et 1, ce qui permet d'interpréter le résultat comme une probabilité.

$$P(Y = 1) = 1 / \left(1 + \exp \left(- \left(m_0 + m_1 x_1 + m_2 x_2 + \dots + m_k x_k \right) \right) \right) \quad (2.2)$$

(Équation 2.2) Fonction logistique appliquée à une combinaison linéaire des caractéristiques.

Interprétation :

- calcul transparent
- structure simple
- coefficients interprétables
- comportement stable et prévisible
- Une visualisation simple = une explication simple.





Modèles intrinsèquement interprétables: Les modèles linéaires

Régression logistique

Propriété	Évaluation
Complétude	Complétude totale atteinte sans avoir besoin de compromis avec l'interprétabilité, le modèle étant intrinsèquement explicable.
Pouvoir expressif	Moins élevé que dans le cas de la régression linéaire. L'interprétation des coefficients n'est pas aussi directe.
Translucidité	Comme tout modèle intrinsèquement explicable, on peut examiner les éléments internes. Les poids sont utilisés pour fournir des explications, mais pas aussi directement que dans la régression linéaire.
Portabilité	La méthode n'est pas portable ; spécifique à la régression logistique.
Complexité algorithmique	Faible, mais pas aussi triviale que pour la régression linéaire.
Compréhensibilité	Les explications sont compréhensibles par les humains, même pour des personnes non techniques.






Modèles intrinsèquement interprétables: Les arbres de décision

Arbres de décision:

Un arbre de décision prend une décision en suivant un ensemble de **règles hiérarchiques** du type if/else.


Interprétation

- Les règles sont visibles
- Le chemin de décision est explicite
- Compréhensible même par non-experts





Example





Modèles intrinsèquement interprétables: Les arbres de décision

Propriétés des explications (arbres de décision)

Propriété	Évaluation
Complétude	Complétude totale atteinte sans avoir besoin de compromis avec l'interprétabilité, le modèle étant intrinsèquement explicable.
Pouvoir expressif	Pouvoir expressif élevé ; en fait, les arbres de décision imitent dans une certaine mesure le raisonnement humain.
Translucidité	Modèle intrinsèquement explicable, facile de deviner comment il prend ses décisions.
Portabilité	De nombreux modèles dérivent des arbres de décision (Random Forest, arbres boostés), donc les résultats des DT peuvent être intégrés dans ces modèles.
Complexité algorithmique	Les arbres de décision sont NP-complets, mais on utilise des heuristiques pour obtenir une évaluation rapide.
Compréhensibilité	Explications faciles à comprendre pour les humains.

