



Explainable Artificial Intelligence

(XAI)





المدرسة الوطنية للذكاء الاصطناعي والرقمنة - بركان
ÉCOLE NATIONALE DE L'INTELLIGENCE ARTIFICIELLE ET DU DIGITAL - BERKANE
«Искусство. Искусство. Искусство» - БРКАН

Chapitre 3

Méthodes Globales Post-Hoc






Introduction aux effets des variables (Feature Effects)

Objectifs d'apprentissage:



- Effets globaux des variables (Global Feature Effects)
- Effets locaux des variables (Local Feature Effects)





Introduction aux effets des variables (Feature Effects)

Effets Des Variables – Vue Globale



ML sans interaction :


$\hat{\beta}_j$ représente l'effet linéaire de la variable X_j (cet effet s'applique globalement à toutes les observations):

- L'équation du modèle est : $\hat{f}(X) = \hat{\beta}_0 + X_1\hat{\beta}_1$.
- La valeur unique $\hat{\beta}_1$ décrit l'effet global de la variable.

GAM sans interaction :


$\hat{f}_j(X_j)$ représente l'effet non linéaire de la variable X_j (cet effet s'applique globalement):

- L'équation du modèle est : $\hat{f}(X) = \hat{\beta}_0 + \hat{f}_j(X_j)$.
- La courbe $\hat{f}_1$ décrit l'effet global de la variable.



Introduction aux effets des variables (Feature Effects)

Effets Des Variables – Vue Locale



- **Interactions** : L'effet d'une variable est modifié par d'autres variables et varie d'une observation à l'autre.
 - ⇒ Par exemple, l'effet de la température varie selon les saisons.
 - ⇒ Il faut donc plusieurs valeurs ou courbes pour décrire cet effet.
- Les modèles d'apprentissage automatique capturent souvent des effets non linéaires et des interactions complexes.
 - ⇒ Cela crée un besoin de méthodes d'analyse des effets locaux, c'est-à-dire l'étude de l'effet pour des observations individuelles.
 - ⇒ Les effets globaux peuvent ensuite être obtenus en agrégeant ces effets locaux.


Introduction aux effets des variables (Feature Effects)

Définition:


Effets Des Variables: Ils permettent de **visualiser** ou de **quantifier** la **contribution marginale** d'une **variable d'intérêt** par rapport aux prédictions.

- Similaire aux **coefficients de régression** dans les modèles linéaires (LM) ou aux **splines** dans les modèles additifs généralisés (GAM).
- Peut être calculé à **différents niveaux d'agrégation** (simplifie l'analyse mais peut entraîner une perte d'information).
- Méthodes courantes : **Graphiques de dépendance partielle (PD plots)**, **Graphiques ALE (Accumulated Local Effects)**, **Effet marginal moyen (AME)**, **Courbes ICE (Individual Conditional Expectation)**


Individual Effects (curves)
ICE plot



Global Effect (curve)
Partial Dependence (PD) plot




Global Effect (aggregated)
AME (e.g., average slope)



Courbe d'Espérance Conditionnelle Individuelle (ICE)

Objectifs d'apprentissage

- Comprendre les courbes ICE comme méthode d'analyse des effets locaux.
- Savoir comment échantillonner des points de grille pour tracer les courbes ICE.







Courbe d'Espérance Conditionnelle Individuelle (ICE)

Motivation

Question : Comment la modification des valeurs d'une seule caractéristique d'une observation affecte-t-elle la prédiction du modèle ?

Idée : Modifier les valeurs de l'observation pour la caractéristique d'intérêt et visualiser comment la prédiction évolue.

Exemple : À partir de la surface de prédiction d'un modèle (à gauche), on sélectionne une observation et on visualise les changements de prédiction pour différentes valeurs de x_2 tout en gardant x_1 fixe $\Rightarrow$ **interprétation locale**.





Courbe d'Espérance Conditionnelle Individuelle (ICE)

On partitionne chaque observation x en deux parties :

- x_S : les caractéristiques d'intérêt
- x_{-S} : les autres caractéristiques

→ En pratique, x_S contient une ou deux caractéristiques (c.-à-d. $|S| \leq 2$ et $-S = S^c$).

	x_S		x_{-S}
i	x_1	x_2	x_3
1	1	4	7
2	2	5	8
3	3	6	9


Les **courbes ICE** visualisent comment la prédiction de la i -ème observation change lorsque l'on fait varier les valeurs de ses caractéristiques d'intérêt S à l'aide de points de grille x_S^* , tout en maintenant fixes toutes les valeurs dans $-S$:

$$\hat{f}_S^{(i)}(x_S^*) \text{ en fonction de } x_S^*$$

où

$$\hat{f}_S^{(i)}(x_S^*) = \hat{f}(x_S^*, x_{-S}^{(i)})$$


est la prédiction pour l'observation i dans laquelle la valeur d'origine $x_S^{(i)}$ a été remplacée par x_S^* .





Courbe d'Espérance Conditionnelle Individuelle (ICE)


Illustration des courbes ICE (Individual Conditional Expectation)



1. Étape – Points de grille :

Échantillonner des valeurs de grille $x_s^{*(1)}, \dots, x_s^{*(g)}$ le long de la caractéristique d'intérêt x_s , puis remplacer dans les données le vecteur $x^{(i)}$ par ces valeurs de grille.

⇒ Cela crée de nouveaux points artificiels pour la i -ème observation (ici : $x_s^* = x_1^* \in \{1, 2, 3\}$ est un scalaire).





Courbe d'Espérance Conditionnelle Individuelle (ICE)


Illustration des courbes ICE (Individual Conditional Expectation)

i	x_1	x_2	x_3
1	1	4	7
2	2	5	8
3	3	6	9

x_s	x_2	x_3	$\hat{f}$
1	4	7	0.4

x_s	x_2	x_3	$\hat{f}$
2	4	7	0.6

x_s	x_2	x_3	$\hat{f}$
3	4	7	0.7



2. Étape – Prédire et visualiser :

Pour chaque point artificiellement créé pour la i -ème observation, représenter la prédiction $\hat{f}_S^{(i)}(x_S^*)$ en fonction des valeurs de grille x_S^* :

$$\hat{f}_1^{(i)}(x_1^*) = \hat{f}(x_1^*, x_{2,3}^{(i)}) \quad \text{pour} \quad x_1^* \in \{1, 2, 3\}.$$






Courbe d'Espérance Conditionnelle Individuelle (ICE)

Illustration des courbes ICE (Individual Conditional Expectation)

i	x_1	x_2	x_3	$\hat{f}_S^{(i)}(x_S^*)$
	x_S	x_2	x_3	$\hat{f}$
1	1	4	7	0.4
2	2	5	8	
3	3	6	9	

x_S	x_2	x_3	$\hat{f}$
2	4	7	0.6

x_S	x_2	x_3	$\hat{f}$
3	4	7	0.7



2. Étape – Prédire et visualiser :

Pour chaque point artificiellement créé pour la i -ème observation, représenter la prédiction $\hat{f}_S^{(i)}(x_S^*)$ en fonction des valeurs de grille x_S^* :

$$\hat{f}_1^{(i)}(x_1^*) = \hat{f}(x_1^*, x_{2,3}^{(i)}) \quad \text{pour} \quad x_1^* \in \{1, 2, 3\}.$$





Courbe d'Espérance Conditionnelle Individuelle (ICE)


Illustration des courbes ICE (Individual Conditional Expectation)

i	x_1	x_2	x_3
1	1	4	7
2	2	5	8
3	3	6	9

x_s	x_2	x_3	$\hat{f}$
1	4	7	0.4

x_s	x_2	x_3	$\hat{f}$
2	4	7	0.6


x_s	x_2	x_3	$\hat{f}$
3	4	7	0.7



2. Étape – Prédire et visualiser :

Pour chaque point artificiellement créé pour la i -ème observation, représenter la prédiction $\hat{f}_s^{(i)}(x_s^*)$ en fonction des valeurs de grille x_s^* :

$$\hat{f}_1^{(i)}(x_1^*) = \hat{f}(x_1^*, x_{2,3}^{(i)}) \quad \text{pour } x_1^* \in \{1, 2, 3\}.$$






Courbe d'Espérance Conditionnelle Individuelle (ICE)

Illustration des courbes ICE (Individual Conditional Expectation)

i	$\mathbf{x}_i$			$\hat{f}$
	x_1	x_2	x_3	
1	1	4	7	0.4
2	2	5	8	0.6
3	3	6	9	0.7

x_s	$\mathbf{x}_i$			$\hat{f}$
	x_1	x_2	x_3	
1	1	5	8	0.6
2	2	5	8	0.8
3	3	5	8	0.9

x_s	$\mathbf{x}_i$			$\hat{f}$
	x_1	x_2	x_3	
3	3	4	7	0.7
3	3	5	8	0.9



3^e étape – Répéter pour les autres observations :

La courbe ICE pour l'observation $i = 2$ relie toutes les prédictions obtenues aux différentes valeurs de la grille, en utilisant les caractéristiques propres à cette deuxième observation.





Courbe d'Espérance Conditionnelle Individuelle (ICE)


Illustration des courbes ICE (Individual Conditional Expectation)

i	$\mathbf{x}_1$	$\mathbf{x}_2$	$\mathbf{x}_3$
1	1	4	7
2	2	5	8
3	3	6	9

$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	4	7	0.4
1	5	8	0.6
1	6	9	0.1

$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
2	4	7	0.6
2	5	8	0.8
2	6	9	0.5

$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
3	4	7	0.7
3	5	8	0.9
3	6	9	0.6



3^e étape – Répéter pour les autres observations :

La courbe ICE pour l'observation $i = 2$ relie toutes les prédictions obtenues aux différentes valeurs de la grille, en utilisant les caractéristiques propres à cette deuxième observation.





Courbe d'Espérance Conditionnelle Individuelle (ICE)

Commentaires sur les valeurs de grille



Tracer des courbes ICE implique de générer des valeurs de grille x_s^* qui seront visualisées sur l'axe des abscisses.

Choix courants pour les valeurs de grille :

- Valeurs **équidistantes** dans l'intervalle de la caractéristique
- Valeurs **échantillonnées aléatoirement**
- Valeurs correspondant aux **quantiles** des observations

Sauf pour les valeurs équidistantes, les deux autres options **préservent approximativement la distribution marginale** de la caractéristique d'intérêt.

⇒ Cela **évite les valeurs irréalistes** pour des distributions contenant des outliers.




Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)

Partial Dependence Plots (PDP)

Objectifs d'apprentissage

- Comprendre les **PDP plots** et leur relation avec les **courbes ICE**
- Savoir **interpréter un PDP**
- Identifier les problèmes d'**extrapolation** et d'**interactions** dans les PDP
- Comprendre les **ICE centrées** et les **PDP centrés**



Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)


Partial Dependence Plots (PDP)

La fonction de dépendance partielle (PD) est l'espérance de $\hat{f}(\mathbf{x}_S, \mathbf{x}_{-S})$ par rapport à la distribution marginale des variables $\mathbf{x}_{-S}$:

$$f_{S,PD}(\mathbf{x}_S) = \mathbb{E}_{\mathbf{x}_{-S}} \left(\hat{f}(\mathbf{x}_S, \mathbf{x}_{-S}) \right) = \int_{-\infty}^{\infty} \hat{f}(\mathbf{x}_S, \mathbf{x}_{-S}) d\mathbb{P}(\mathbf{x}_{-S})$$

- **Estimation** : Pour une valeur de grille x_S^* , on moyenne les courbes ICE point par point en x_S^* sur toutes les valeurs observées $x_{-S}^{(i)}$

$$\hat{f}_{S,PD}(\mathbf{x}_S^*) = \frac{1}{n} \sum_{i=1}^n \hat{f}(\mathbf{x}_S^*, \mathbf{x}_{-S}^{(i)})$$



Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)

EXEMPLE : DÉPENDANCE PARTIELLE POUR UN MODÈLE LINÉAIRE

Considérons un modèle de régression linéaire avec deux variables :


$$\hat{f}(\mathbf{x}) = \hat{f}(\mathbf{x}_1, \mathbf{x}_2) = \hat{\beta}_1 \mathbf{x}_1 + \hat{\beta}_2 \mathbf{x}_2 + \hat{\beta}_0$$

La fonction de dépendance partielle (PD) pour la variable d'intérêt $S=\{1\}$ (avec $-S=\{2\}$) est :

$$\begin{aligned} f_{1,PD}(\mathbf{x}_1) &= \mathbb{E}_{\mathbf{x}_2} \left(\hat{f}(\mathbf{x}_1, \mathbf{x}_2) \right) = \int_{-\infty}^{\infty} \left(\hat{\beta}_1 \mathbf{x}_1 + \hat{\beta}_2 \mathbf{x}_2 + \hat{\beta}_0 \right) d\mathbb{P}(\mathbf{x}_2) \\ &= \hat{\beta}_1 \mathbf{x}_1 + \hat{\beta}_2 \cdot \int_{-\infty}^{\infty} \mathbf{x}_2 d\mathbb{P}(\mathbf{x}_2) + \hat{\beta}_0 \\ &= \hat{\beta}_1 \mathbf{x}_1 + \underbrace{\hat{\beta}_2 \cdot \mathbb{E}_{\mathbf{x}_2}(\mathbf{x}_2)}_{:=const} + \hat{\beta}_0 \end{aligned}$$

=> Le graphique PD représente la fonction : $f_{1,PD}(\mathbf{x}_1) = \hat{\beta}_1 \mathbf{x}_1 + const$

(c'est-à-dire **l'effet de la variable x_1** dans un modèle linéaire)



Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)


PARTIAL DEPENDENCE

i	$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	1	4	7	0.4
2	1	5	8	0.6
3	1	6	9	0.1

i	$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	2	4	7	0.6
2	2	5	8	0.8
3	2	6	9	0.5

i	$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	3	4	7	0.7
2	3	5	8	0.9
3	3	6	9	0.6

$\frac{1}{3} \sum_{i=1}^3 \hat{f}$
$\frac{1}{3} (0.4 + 0.6 + 0.1)$
$\frac{1}{3} (0.6 + 0.8 + 0.5)$
$\frac{1}{3} (0.7 + 0.9 + 0.6)$



Estimer la fonction de dépendance partielle (PD) en faisant la moyenne **point par point** des courbes

ICE à la valeur de grille

$$\mathbf{x}_s^* = \mathbf{x}_1^* = 1 :$$

$$\hat{f}_{1,PD}(\mathbf{x}_1^*) = \frac{1}{n} \sum_{i=1}^n \hat{f}(\mathbf{x}_1^*, \mathbf{x}_{2,3}^{(i)})$$

Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)


PARTIAL DEPENDENCE

i	$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	1	4	7	0.4
2	1	5	8	0.6
3	1	6	9	0.1

i	$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	2	4	7	0.6
2	2	5	8	0.8
3	2	6	9	0.5

$\frac{1}{3} \sum_{i=1}^3 \hat{f}$
$\frac{1}{3} (0.4 + 0.6 + 0.1)$
$\frac{1}{3} (0.6 + 0.8 + 0.5)$
$\frac{1}{3} (0.7 + 0.9 + 0.6)$

i	$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	3	4	7	0.7
2	3	5	8	0.9
3	3	6	9	0.6



Estimer la fonction de dépendance partielle (PD) en faisant la moyenne **point par point** des courbes

ICE à la valeur de grille $\mathbf{x}_s^* = \mathbf{x}_1^* = 2$:

$$\hat{f}_{1,PD}(\mathbf{x}_1^*) = \frac{1}{n} \sum_{i=1}^n \hat{f}(\mathbf{x}_1^*, \mathbf{x}_{2,3}^{(i)})$$

Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)


PARTIAL DEPENDENCE

i	$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	1	4	7	0.4
2	1	5	8	0.6
3	1	6	9	0.1

i	$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	2	4	7	0.6
2	2	5	8	0.8
3	2	6	9	0.5

i	$\mathbf{x}_s$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\hat{f}$
1	3	4	7	0.7
2	3	5	8	0.9
3	3	6	9	0.6

$\frac{1}{3} \sum_{i=1}^3 \hat{f}$
$\frac{1}{3} (0.4 + 0.6 + 0.1)$
$\frac{1}{3} (0.6 + 0.8 + 0.5)$
$\frac{1}{3} (0.7 + 0.9 + 0.6)$



Estimer la fonction de dépendance partielle (PD) en faisant la moyenne **point par point** des courbes ICE à la valeur de grille $\mathbf{x}_s^* = x_1^* = 3$:


$$\hat{f}_{1,PD}(x_1^*) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x_1^*, \mathbf{x}_{2,3}^{(i)})$$

Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)

INTERPRÉTATION: PDP ET ICE

Lorsque la variable varie :

- **ICE** : comment la prédiction d'une **observation individuelle** change-t-elle ?
⇒ **interprétation locale**
- **PD** : comment l'effet moyen / la **prédiction attendue** change-t-elle ?
⇒ **interprétation globale**




Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)

INTERPRÉTATION: PDP ET ICE

Lorsque la variable varie :

- **ICE** : comment la prédiction d'une **observation individuelle** change-t-elle ?
⇒ **interprétation locale**
- **PD** : comment l'effet moyen / la **prédiction attendue** change-t-elle ?
⇒ **interprétation globale**





Constats tirés des données de location de vélos :

- Des courbes ICE parallèles = **effet homogène**
- Plus il fait chaud ⇒ **plus de vélos loués**
- Trop chaud ⇒ **légère baisse** du nombre de vélos loués


Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)

INTERPRÉTATION : VARIABLES CATÉGORIELLES



- **PDP** : utiliser des **boîtes à moustaches (boxplots)**
- **ICE** : utiliser des **graphiques en coordonnées parallèles**



NB : Les catégories peuvent être **non ordonnées** ; dans ce cas, il est préférable de faire des **comparaisons par paires**.



Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)

COMMENTAIRES SUR L'EXTRAPOLATION

L'extrapolation peut poser problème dans les zones où il y a peu d'observations ou lorsque les variables sont corrélées.



- **Exemple** : Les variables x_1 et x_2 sont fortement corrélées.
- **Points noirs** : points réellement observés dans les données
- **Points rouges** : points de grille utilisés pour calculer les courbes ICE et PD (certains de ces points sont irréalistes)



⇒ Le graphique PD à $x_1=0$ moyenne les prédictions sur **toute la distribution marginale** de x_2 .

⇒ Cela peut être problématique si le modèle se comporte mal **en dehors du domaine d'entraînement**.

Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)


COMMENTAIRES SUR LES INTERACTIONS

- Les graphiques PD moyennent les courbes ICE, ce qui peut masquer les effets hétérogènes et les interactions.
 - ⇒ Il est recommandé d'afficher ensemble **les ICE** et **les PD** pour révéler ces phénomènes.
 - ⇒ Des formes différentes entre courbes ICE indiquent une interaction (mais sans préciser avec quelle variable).



Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)

COMMENTAIRES SUR LES INTERACTIONS- DÉPENDANCE PARTIELLE EN 2D



- L'humidité et la température **interagissent** pour des valeurs élevées (voir la différence de forme).
⇒ La forme des courbes ICE varie selon les tranches horizontales ou verticales (à haute humidité ou haute température).
- Humidité faible à moyenne + température élevée ⇒ beaucoup de vélos loués.

Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)

C-ICE : COURBES ICE CENTRÉES


- **Problème** : Difficile d'identifier l'hétérogénéité des courbes ICE lorsqu'elles ont des **intercepts différents** (elles se superposent verticalement).
- **Solution** : Centrer les courbes ICE à une **valeur de référence** $x' \sim P(x_S)$ tirée de la distribution , souvent $x' = \min(x_S)$.

⇒ Les courbes c-ICE permettent plus facilement de repérer les formes hétérogènes.

La courbe centrée est définie par :

$$\begin{aligned}\hat{f}_{S,cICE}^{(i)}(\mathbf{x}_S) &= \hat{f}(\mathbf{x}_S, \mathbf{x}_{-S}^{(i)}) - \hat{f}(x', \mathbf{x}_{-S}^{(i)}) \\ &= \hat{f}_S^{(i)}(\mathbf{x}_S) - \hat{f}_S^{(i)}(x')\end{aligned}$$

⇒ On visualise $\hat{f}_{S,cICE}^{(i)}(\mathbf{x}_S^*)$ en fonction du point de grille x_S^* .



Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)

C-ICE : COURBES ICE CENTRÉES

- **Problème** : Difficile d'identifier l'hétérogénéité des courbes ICE lorsqu'elles ont des **intercepts différents** (elles se superposent verticalement).
- **Solution** : Centrer les courbes ICE à une **valeur de référence** $x' \sim P(x_S)$ tirée de la distribution, souvent $x' = \min(x_S)$.

⇒ Les courbes c-ICE permettent plus facilement de repérer les formes hétérogènes.


La courbe centrée est définie par :

$$\begin{aligned}\hat{f}_{S, cICE}^{(i)}(\mathbf{x}_S) &= \hat{f}(\mathbf{x}_S, \mathbf{x}_{-S}^{(i)}) - \hat{f}(x', \mathbf{x}_{-S}^{(i)}) \\ &= \hat{f}_S^{(i)}(\mathbf{x}_S) - \hat{f}_S^{(i)}(x')\end{aligned}$$

⇒ On visualise $\hat{f}_{S, cICE}^{(i)}(\mathbf{x}_S^*)$ en fonction du point de grille x_S^* .

Interprétation (courbe jaune dans le c-ICE) :


En moyenne, le nombre de vélos loués à environ **97 % d'humidité** diminue d'environ **1000 locations** par rapport à une humidité de **0 %**.



Graphiques de Dépendance Partielle (Partial Dependence Plots – PDP)


C-ICE : COURBES ICE CENTRÉES

Pour les variables catégorielles, les graphiques c-ICE peuvent s'interpréter comme dans les modèles linéaires grâce à la catégorie de référence.



Interprétation :

- La catégorie de référence est $x' = \text{SPRING}$
- Les croix dorées représentent le **nombre moyen de vélos loués** lorsqu'on passe de SPRING à une autre saison.
⇒ Le nombre de vélos loués **baisse d'environ 560** en **WINTER**, et il est légèrement plus élevé en **SUMMER** et **FALL** par rapport à SPRING.






Accumulated Local Effect (ALE) plot

Accumulated Local Effect (ALE) plot

Objectifs d'apprentissage



- Les graphiques PD (Partial Dependence) et leurs problèmes d'extrapolation
- Les graphiques M et leur biais dû aux variables omises
- Comprendre les graphiques ALE (Accumulated Local Effects)





Accumulated Local Effect (ALE) plot

Motivation – Variables corrélées




- Les graphiques PD **moyennent des prédictions** sur des points artificiels, hors distribution / peu probables (en rouge).
- ⇒ Cela peut conduire à des interprétations trompeuses / biaisées, surtout si le modèle contient des interactions.
- Ce n'est pas souhaitable lorsque l'on veut interpréter les effets à l'intérieur de la distribution réelle des données.


Accumulated Local Effect (ALE) plot

Motivation – Variables corrélées

Exemple: On ajuste un réseau de neurones (NN) sur **5000 points simulés** avec : $x \sim \text{Unif}(0,1)$, $\epsilon \sim N(0,0.2)$, $y = x_1 + x_2^2 + \epsilon$, où $x_1 = x + \epsilon_1$, $x_2 = x + \epsilon_2$ et $\epsilon_1, \epsilon_2 \sim N(0,0.05)$.




- L'erreur de test (MSE) du réseau de neurones est **comparable à celle d'autres modèles**.
- Le réseau de neurones **contient des interactions** (ce que montre la surface de prédiction complexe).



Accumulated Local Effect (ALE) plot

Motivation – Variables corrélées

Exemple: On ajuste un réseau de neurones (NN) sur **5000 points simulés** avec : $x \sim \text{Unif}(0,1)$, $\epsilon \sim N(0,0.2)$, $y = x_1 + x_2^2 + \epsilon$, où $x_1 = x + \epsilon_1$, $x_2 = x + \epsilon_2$ et $\epsilon_1, \epsilon_2 \sim N(0,0.05)$.




- L'erreur de test (MSE) du réseau de neurones est **comparable à celle d'autres modèles**.
- Le réseau de neurones **contient des interactions** (ce que montre la surface de prédiction complexe).
- Les graphiques **ALE** sont cohérents avec la **vérité terrain** (ground truth).
- Les graphiques **PDP** ne reflètent pas bien les effets réels du **processus générateur des données (DGP)**.
⇒ À cause des **interactions** et de la **moyenne de points situés en dehors de la distribution des données**.


Accumulated Local Effect (ALE) plot

M Plot vs. PD Plot

a) PD plot :




L'expression $\mathbb{E}_{\mathbf{x}_2} \left(\hat{f}(x_1, \mathbf{x}_2) \right)$ est estimée par : $\hat{f}_{1,PD}(x_1) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x_1, \mathbf{x}_2^{(i)})$




Accumulated Local Effect (ALE) plot

M Plot vs. PD Plot

a) PD plot :



b) M plot





a) L'expression $\mathbb{E}_{\mathbf{x}_2} \left(\hat{f}(x_1, \mathbf{x}_2) \right)$ est estimée par : $\hat{f}_{1,PD}(x_1) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x_1, \mathbf{x}_2^{(i)})$

b) M plot $\mathbb{E}_{\mathbf{x}_2 | \mathbf{x}_1} \left(\hat{f}(x_1, \mathbf{x}_2) | \mathbf{x}_1 \right)$ est estimé par : $\hat{f}_{1,M}(x_1) = \frac{1}{|N(x_1)|} \sum_{i \in N(x_1)} \hat{f}(x_1, \mathbf{x}_2^{(i)})$, où l'ensemble


d'indices $N(x_1) = \{i : x_1^{(i)} \in [x_1 - \epsilon, x_1 + \epsilon]\}$ correspond aux observations dont la valeur du feature est proche de x_1 .

Accumulated Local Effect (ALE) plot

M Plot vs. PD Plot



- **M plots average predictions over the conditional distribution (ex. $P(x_2 \mid x_1)$).**
 - Ils moyennent les prédictions là où les données existent réellement, ce qui évite les problèmes d'extrapolation.
- **Mais : les M plots souffrent de l'OBV (omitted-variable bias).**
 - Ils capturent aussi les effets des autres variables corrélées avec x_1 .
 - Donc ils sont inutiles pour évaluer l'effet marginal réel de x_1 lorsque des dépendances entre features sont présentes.



Accumulated Local Effect (ALE) plot

M Plot vs. PD Plot - OVB EXAMPLE






Illustration : On ajuste un modèle linéaire (LM) sur **500 observations i.i.d.** avec $x_1, x_2 \sim N(0, 1)$, $Cor(x_1, x_2) = 0.9$ et $y = -x_1 + 2 \cdot x_2 + \epsilon$, $\epsilon \sim N(0, 1)$.

Résultat : le M plot de x_1 inclut également l'effet marginal de toutes les autres variables dépendantes (ici : x_2)





Accumulated Local Effect (ALE) plot

IDÉE : INTÉGRER LES DÉRIVÉES PARTIELLE

L'idée est la suivante : pour éliminer les effets indésirables des autres variables, on calcule les dérivées partielles (effets locaux) de la fonction de prédiction par rapport à la variable d'intérêt, puis on les intègre (on les cumule) par rapport à cette même variable.


⇒ **Calculer la dérivée partielle de $\hat{f}$ par rapport à x_j** élimine les autres effets principaux.

⇒ **Intégrer de nouveau par rapport à x_j** permet de retrouver l'effet principal original de x_j .

Exemple :

Considérons une fonction de prédiction additive :

$$\hat{f}(x_1, x_2) = 2x_1 + 2x_2 - 4x_1x_2$$





Accumulated Local Effect (ALE) plot

IDÉE : INTÉGRER LES DÉRIVÉES PARTIELLE


Dérivée partielle de $\hat{f}$ par rapport à x_1 :

$$\frac{\partial \hat{f}(x_1, x_2)}{\partial x_1} = 2 - 4x_2.$$

Intégrale de la dérivée partielle (avec $z_0 = \min(x_1)$) :

$$\int_{z_0}^x \frac{\partial \hat{f}(x_1, x_2)}{\partial x_1} dx_1 = [2x_1 - 4x_1x_2]_{z_0}^x$$

Nous avons ainsi **supprimé l'effet principal de x_2** , ce qui était notre objectif.





ALE d'ordre 1 (First Order ALE)

Les **graphiques ALE** (Accumulated Local Effects) utilisent l'idée d'**intégrer les dérivées partielles**.

Ils ne souffrent ni du problème d'extrapolation des PD plots, ni du **biais de variable omise (OVB)** des M plots lorsque les caractéristiques sont dépendantes.

Le concept des ALE plots repose sur :

1. Estimer les effets locaux

$$\frac{\partial \hat{f}(x_S, x_{-S})}{\partial x_S}$$

(via des différences finies) évalués en certains points ($x_S = z_S, x_{-S}$).


2. Moyenner les effets locaux sur la distribution conditionnelle $P(x_{-S}|x_S)P(x_{-S} \mid x_S)P(x_{-S}|x_S)$, de manière similaire aux M plots

⇒ **Évite le problème d'extrapolation.**

3. Intégrer les effets locaux moyens jusqu'à une valeur spécifique $x \sim P(x_S)x \sim P(x_S)x \sim P(x_S)$

⇒ **Accumule les effets locaux** pour estimer l'effet principal global de x_S

⇒ **Évite le problème d'OVB**, car les autres effets principaux indésirables ont été supprimés à l'étape (1).






Accumulated Local Effect (ALE) plot

Accumulated Local Effect (ALE) plot

Soit x_S la caractéristique d'intérêt, avec $z_0 = \min(x_S)$, et x_{-S} l'ensemble des autres caractéristiques (complément de S).

L'ALE d'ordre 1 non centrée $\tilde{f}_{S,\text{ALE}}(x)$ pour une valeur de la caractéristique $x \sim P(x_S)$ est définie comme :

$$\tilde{f}_{S,\text{ALE}}(x) = \underbrace{\int_{z_0}^x}_{(3)} \underbrace{\mathbb{E}_{x_{-S}|x_S}}_{(2)} \underbrace{\frac{\partial \hat{f}(x_S, x_{-S})}{\partial x_S} \Big|_{x_S=z_S}}_{(1)} dz_S$$






Accumulated Local Effect (ALE) plot

Accumulated Local Effect (ALE) plot

Pour obtenir la **courbe ALE centrée** $f_{S,\text{ALE}}(x)$ avec une moyenne nulle par rapport à la distribution marginale de x_S , on soustrait la moyenne de la courbe non centrée :

$$f_{S,\text{ALE}}(x) = \tilde{f}_{S,\text{ALE}}(x) - \underbrace{\int_{-\infty}^{\infty} \tilde{f}_{S,\text{ALE}}(x_S) dP(x_S)}_{\text{constante}}$$






Accumulated Local Effect (ALE) plot

Estimation des ALE

Les dérivées partielles ne sont pas utilisables pour tous les modèles (par exemple, les modèles à arbres comme les random forests).

On **approxime donc les dérivées partielles** à l'aide de **différences finies** des prédictions, en découpant la variable x_S en **K intervalles** :

$$x \in [\min(x_S), \max(x_S)] \iff x \in [z_{0,S}, z_{1,S}] \vee x \in]z_{1,S}, z_{2,S}] \vee \dots \vee x \in]z_{K-1,S}, z_{K,S}]$$






Accumulated Local Effect (ALE) plot

Estimation des ALE

Une manière simple de créer ces **K intervalles** consiste à utiliser la **distribution des quantiles** de la variable x_S :
on choisit **K – 1 quantiles** comme bornes d'intervalles

$$z_{1,S}, \dots, z_{K-1,S}$$

(sans compter les quantiles 0 % et 100 % qui correspondent déjà au min et max).





Accumulated Local Effect (ALE) plot

2-D ILLUSTRATION


Étapes de calcul des ALE

- Diviser la variable d'intérêt en intervalles (lignes verticales).
- Pour tous les points appartenant à un même intervalle, calculer la différence de prédiction lorsque l'on remplace la valeur de la variable :
 - par la **borne inférieure** de l'intervalle,
 - puis par la **borne supérieure** (points bleus),
tout en gardant **les autres variables inchangées**.
- Ces **différences finies** (approximation de l'effet local) sont ensuite :
 - **accumulées** le long des intervalles,
 - puis **centrées**,
⇒ ce qui donne la **courbe ALE**.



Accumulated Local Effect (ALE) plot

2-D ILLUSTRATION



Pour une observation $x^{(i)} = (x_S^{(i)}, x_{-S}^{(i)})$, la valeur $x_S^{(i)}$ se situe dans le **k-ième intervalle** de la variable x_S (c'est-à-dire $x_S^{(i)} \in]z_{k-1,S}, z_{k,S}]$).

On remplace alors $x_S^{(i)}$ par :


- la **borne inférieure** de l'intervalle $z_{k-1,S}$,
- puis la **borne supérieure** de l'intervalle $z_{k,S}$,






Accumulated Local Effect (ALE) plot

2-D ILLUSTRATION




Les **différences finies** (approximation de l'effet local) sont alors :

$$\hat{f}(z_{k,S}, x_{-S}^{(i)}) - \hat{f}(z_{k-1,S}, x_{-S}^{(i)})$$



Accumulated Local Effect (ALE) plot

2-D ILLUSTRATION



Estimer l'effet local de x_S dans chaque intervalle en moyennant toutes les différences finies observation par observation

$\hat{\cdot}$ = approximation de l'intégrale interne qui intègre les effets locaux par rapport à $P(x_{-S} \mid z_S)$.

Additionner les effets locaux de tous les intervalles jusqu'au point d'intérêt

$\hat{\cdot}$ = estimation de l'intégrale externe.





Accumulated Local Effect (ALE) plot


Estimation ale : Formule

L'ALE d'ordre 1 non centrée estimée $\tilde{f}_{S,ALE}(x)$ au point x :

$$\hat{\tilde{f}}_{S,ALE}(x) = \sum_{k=1}^{k_S(x)} \frac{1}{n_S(k)} \sum_{i: x_S^{(i)} \in]z_{k-1,S}, z_{k,S}]} [\hat{f}(z_{k,S}, x_{-S}^{(i)}) - \hat{f}(z_{k-1,S}, x_{-S}^{(i)})]$$

$k_S(x)$ désigne l'indice de l'intervalle dans lequel la valeur $x \in x_S$ tombe.

$n_S(k)$ désigne le nombre d'observations appartenant au k -ème intervalle de x_S .






Accumulated Local Effect (ALE) plot

Estimation ale : Formule

Soustraire la moyenne de l'ALE non centrée estimée pour obtenir l'estimation centrée de l'ALE :

$$\hat{f}_{S,ALE}(x) = \hat{\tilde{f}}_{S,ALE}(x) - \frac{1}{n} \sum_{i=1}^n \hat{\tilde{f}}_{S,ALE}(x_S^{(i)})$$






Accumulated Local Effect (ALE) plot



Estimation ale : algorithme

1. Créer K intervalles pour la plage de valeurs de x_S .
2. Répéter pour chaque intervalle :
 - Remplacer la valeur de la caractéristique $x_S^{(i)}$ d'une observation par la borne supérieure/inférieure de l'intervalle pour chaque observation appartenant au k -ème intervalle.
 - Calculer les différences finies par observation à l'intérieur du k -ème intervalle et les moyenner pour estimer les effets locaux par intervalle.
3. Accumuler les effets locaux des intervalles jusqu'à la valeur d'intérêt x pour estimer l'ALE non centrée, puis la centrer.



Accumulated Local Effect (ALE) plot



Exemple-Simple



- Les graphiques PD **moyennent des prédictions** sur des points artificiels, hors distribution / peu probables (en rouge).
- ⇒ Cela peut conduire à des interprétations trompeuses / biaisées, surtout si le modèle contient des interactions.
- Ce n'est pas souhaitable lorsque l'on veut interpréter les effets à l'intérieur de la distribution réelle des données.




Accumulated Local Effect (ALE) plot

Exemple-Simple




Accumulated Local Effect (ALE) plot

Exemple-Simple



$$\text{effect in interval} = \frac{1}{n} \sum_{i=1}^n f(\text{green instance}) - f(\text{orange instance})$$





Accumulated Local Effect (ALE) plot

Estimation ale : algorithme

1. Initialisation


$$ALE(x) = 0$$

où $ALE(x)$ représente l'effet local accumulé pour la caractéristique x .

2. Définition des intervalles

Diviser l'étendue de la caractéristique x en k intervalles.

Soient $x_{i,\min}$ et $x_{i,\max}$ les valeurs minimale et maximale du i -ème intervalle, respectivement.





Accumulated Local Effect (ALE) plot

Estimation ale : algorithme

3. Calcul des effets locaux pour chaque intervalle

Pour chaque intervalle $i = 1, 2, \dots, k$, procéder comme suit :

(a) Identifier le sous-ensemble des points de données S_i pour lesquels x appartient à l'intervalle $[x_{i,\min}, x_{i,\max}]$.


(b) Calculer l'effet moyen dans cet intervalle :

$$\text{effet}_i = \frac{1}{|S_i|} \sum_{j \in S_i} [f(x_j^+) - f(x_j^-)]$$

où $f(x)$ est la fonction de prédiction du modèle,

x_j^+ est le point de données j avec la caractéristique x remplacée par $x_{i,\max}$,

et x_j^- est le même point de données avec x remplacée par $x_{i,\min}$.





Accumulated Local Effect (ALE) plot

Estimation ale : algorithme

4. Accumulation des effets

Mettre à jour l'ALE pour chaque intervalle :

$$ALE(x_{i,\max}) = ALE(x_{i,\min}) + \text{effet}_i$$


Ici, $ALE(x_{i,\max})$ correspond à l'effet accumulé jusqu'à la borne supérieure du i -ème intervalle.

5. Répéter pour tous les intervalles

Répéter les étapes 3 et 4 pour tous les intervalles $i = 1, 2, \dots, k$.

6. Valeurs finales de l'ALE

Les valeurs finales de l'ALE sont obtenues pour chaque intervalle et combinées pour former un ensemble de données.



Accumulated Local Effect (ALE) plot

Estimation ale : algorithme

7. Centrage de l'ALE


Les valeurs sont généralement centrées afin de faciliter l'interprétation de l'effet sur les prédictions du modèle.

Cela se fait en soustrayant la valeur moyenne de l'ALE sur l'ensemble du jeu de données à chaque valeur individuelle :

$$ALE_{\text{centré}}(x) = ALE(x) - \overline{ALE}$$

8. Visualisation (optionnelle)



Tracer $ALE_{\text{centré}}(x)$ en fonction de x afin de visualiser l'effet de la caractéristique sur le modèle.



Accumulated Local Effect (ALE) plot

Jeu de données bike sharing : ale d'ordre 1


La forme du graphique PD (à gauche) ressemble souvent à celle du graphique ALE d'ordre 1 centré (à droite), mais avec une échelle différente sur l'axe des ordonnées. En présence de caractéristiques corrélées, l'ALE peut être préférable car les PD souffrent d'un problème d'extrapolation.





Accumulated Local Effect (ALE) plot

Jeu de données bike sharing : ale d'ordre 2

Bivariate PD



Second order ALE





Accumulated Local Effect (ALE) plot


PD VS. ALE

PD :

$$f_{S,PD}(x_S) = \mathbb{E}_{x_{-S}} [\hat{f}(x_S, x_{-S})]$$

ALE :

$$f_{S,ALE}(x) = \int_{z_0}^x \mathbb{E}_{x_{-S} | x_S} \left[\frac{\partial \hat{f}(x_S, x_{-S})}{\partial x_S} \Big|_{x_S=z_S} \right] dz_S - \text{const}$$





Accumulated Local Effect (ALE) plot

PD VS. ALE

Rappel :

Les PD font une moyenne directe des prédictions sur la **distribution marginale** de x_{-S} .


Différence 1 :

Les ALE font une moyenne du **changement des prédictions** (via les dérivées partielles, approximées par des différences finies) sur la **distribution conditionnelle** $P(x_{-S} \mid x_S = z_S)$.

Différence 2 :

Les ALE intègrent les **dérivées partielles** de la variable S sur z_S

→ ce qui isole l'effet de la variable S et supprime les effets principaux des autres variables dépendantes.





Accumulated Local Effect (ALE) plot


PD VS. ALE

PD:

$$f_{S,PD}(x_S) = \mathbb{E}_{\mathbf{x}_{-S}} \left(\hat{f}(x_S, \mathbf{x}_{-S}) \right)$$

ALE:

$$f_{S,ALE}(x) = \int_{z_0}^x \mathbf{E}_{\mathbf{x}_{-S}|x_S} \left(\left. \frac{\partial \hat{f}(x_S, \mathbf{x}_{-S})}{\partial x_S} \right|_{x_S = z_S} \right) dz_S - \text{const}$$





Accumulated Local Effect (ALE) plot

PD VS. ALE

Rappel : Les PD font une moyenne directe des prédictions sur la **distribution marginale** de x_{-S} .

Différence 1 : Les ALE font une moyenne du **changement des prédictions** (via les dérivées partielles, approximées par des différences finies) sur la **distribution conditionnelle** $P(x_{-S} \mid x_S = z_S)$.

Différence 2 : Les ALE intègrent les **dérivées partielles** de la variable S sur z_S
→ ce qui isole l'effet de la variable S et supprime les effets principaux des autres variables dépendantes.

Différence 3 : Les ALE sont **centrées** de sorte que $\mathbb{E}_{x_S}[f_{S,ALE}(x)] = 0$.

