



Explainable Artificial Intelligence

(XAI)





المدرسة الوطنية للذكاء الاصطناعي والرقمنة - بركان
ÉCOLE NATIONALE DE L'INTELLIGENCE ARTIFICIELLE ET DU DIGITAL - BERKANE
ΟΙΚΟΔΟΜΗ ΣΗΜΕΙΩΣΗ ΜΗΜΑΡΟ ΜΟΘΕΙΟΝ ΧΟΗΘΕΙΟ - ΘΟΚΟΙ

Chapitre 4

Méthodes Locales post-hoc
SHapley **A**dditive ex**P**lanation
(**SHAP**)





SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)



Lloyd Shapley

Prix Nobel d'économie 2012.


Il a été récompensé pour ses travaux en **théorie des jeux**, en particulier sur la **théorie des allocations stables**.





SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)



Robotics competition



\$10000 prize money



Quelle est une répartition équitable de l'argent du prix ?



SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

Une répartition égale est-elle équitable ?



Injuste envers les contributeurs majeurs



\$10000 prize money






SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

Contribution individuelle



2nd place
\$6000 prize money





SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

S'agit-il d'une estimation correcte de la contribution ?

Hardware Expert



\$2000



\$2000



\$2000



\$4000



2nd place

\$6000 prize money

Une répartition Injuste







SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

Comment estimer la contribution individuelle ?






SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

Il est nécessaire de considérer différents sous-ensembles



\$10000 prize money






SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

Il est nécessaire de considérer différents sous-ensembles



2nd place
\$6000 prize money







SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

Il est nécessaire de considérer différents sous-ensembles






SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

Il est nécessaire de considérer différents sous-ensembles







SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

Il est nécessaire de considérer différents sous-ensembles






SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

- Pour calculer la contribution individuelle réelle, il est nécessaire de considérer **différents sous-ensembles**.
- Il faut calculer la **contribution de l'individu pour chaque sous-ensemble**, puis faire la **moyenne de ces contributions** afin d'obtenir la contribution marginale de chaque joueur.






SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)

Considérons l'analogie en apprentissage automatique (ML).



Age

Exercise
duration

BMI

Diabetic
parents

Caloric intake



Si le modèle de ML prédit que cette personne est diabétique, quelle caractéristique (feature) a le plus contribué à cette prédiction et dans quelle mesure ?



SHapley Additive exPlanation

SHAP (SHapley Additive exPlanation)


Intuition derrière SHAP.





SHapley Additive exPlanation


SHAP Math (SHapley Additive exPlanation)






SHapley Additive exPlanation

SHAP avec des données textuelles



Avis de films **positifs et négatifs**. Le **bleu** indique les phrases qui ont **contribué négativement** à l'avis, ainsi que l'ampleur de cette contribution. Le **rouge** indique les contributions **positives**.






SHapley Additive exPlanation

SHAP avec des Images

SHAP With Image Data



Le rouge met en évidence les pixels ayant contribué positivement à la classification, ainsi que l'ampleur de cette contribution. Les pixels bleus indiquent une contribution négative.






SHapley Additive exPlanation

SHAP avec des données tabulaires

Prédire la probabilité qu'un individu perçoive un revenu annuel supérieur à 50 k \$.










Plutôt que d'utiliser un histogramme classique d'importance des caractéristiques, nous utilisons un nuage de points de densité des valeurs SHAP pour chaque caractéristique afin d'identifier l'impact de chaque caractéristique sur la sortie du modèle pour les individus du jeu de données de validation.





SHapley Additive exPlanation

Types of SHAP Plots






SHapley Additive exPlanation

Exp: Importance des caractéristiques

Interprétation :

- Les caractéristiques température et année ont de loin la plus grande influence sur la prédiction du modèle
- Par rapport aux valeurs de Shapley, aucune direction d'effet n'est fournie, mais plutôt un classement des caractéristiques similaire à l'IPF (Permutation Feature Importance)
- Cependant, l'importance SHAP est basée uniquement sur les prédictions du modèle, tandis que l'IPF est basée sur la performance du modèle (perte)






SHapley Additive exPlanation

Exp: Graphique de synthèse

Combine l'importance des caractéristiques avec leurs effets
Chaque point est une valeur de Shapley pour une caractéristique et une observation
La couleur représente la valeur de la caractéristique de basse à haute
Les points qui se chevauchent sont dispersés dans la direction de l'axe des y

Interprétation :

- Les basses températures ont un impact négatif tandis que les hautes températures entraînent plus de locations de vélos
- Année : deux nuages de points pour 2011 et 2012 (les autres caractéristiques catégorielles sont en gris)
- Une humidité élevée a un impact énorme et négatif sur la location de vélos, tandis qu'une faible humidité a un impact positif plutôt mineur sur les locations de vélos






SHapley Additive exPlanation

Graphique de dépendance

- Visualiser la contribution marginale d'une caractéristique de manière similaire au PDP (Partial Dependence Plot)
- Tracer un point avec la valeur de la caractéristique sur l'axe des x et la valeur de Shapley correspondante sur l'axe des y

Interprétation :

- Des températures croissantes induisent des locations de vélos croissantes jusqu'à 25°C
- S'il fait trop chaud, les locations de vélos diminuent






SHapley Additive exPlanation

Graphique de dépendance

- Nous pouvons colorer les observations par une deuxième caractéristique pour détecter les interactions
- Visiblement, l'interaction des températures avec la saison est très forte





SHapley Additive exPlanation

Référence SHAP

A Unified Approach to Interpreting Model Predictions:
<https://arxiv.org/abs/1705.07874>

