




المدرسة الوطنية للذكاء الاصطناعي والرقمنة - بركان
ÉCOLE NATIONALE DE L'INTELLIGENCE ARTIFICIELLE ET DU DIGITAL - BERKANE
ⵎⵔⵓⵙⵉ ⵏ ⵓⵔⵓⵎⵉⵏ ⵏ ⵓⵔⵓⵎⵉⵏ ⵏ ⵓⵔⵓⵎⵉⵏ ⵏ ⵓⵔⵓⵎⵉⵏ ⵏ ⵓⵔⵓⵎⵉⵏ - ⵔⵓⵔⵓⵎⵉⵏ

Explainable Artificial Intelligence (XAI)





Méthodes Locales post-hoc

Local Interpretable Model-agnostic Explanations (LIME)





Local Interpretable Model-agnostic Explanations

Qu'est-ce que LIME ?

- Local

- Interpretable

- Model-agnostic

- Explanations

- Méthode d'explication locale autour d'une instance donnée

- L'explication doit être compréhensible par un humain

- Indépendante du modèle (applicable à tous les types de modèles)


- Fournit une explication facilitant l'interprétation des prédictions du modèle



Local Interpretable Model-agnostic Explanations

Interprétabilité Globale Vs Locale

Global and Local Interpretability



Quelle est la caractéristique qui différencie ces deux individus ?

Pourquoi le modèle global classe-t-il l'individu bleu comme étant en mauvaise santé ?





Local Interpretable Model-agnostic Explanations

Classification de textes

I have a medical emergency. Hence won't be able to attend the meeting today.	Important
Hi may I get the information about your service?	Not important


I have a medical emergency . Hence won't be able to attend the meeting today.	Important
Hi may I get the information about your service ?	Not important



Local Interpretable Model-agnostic Explanations

Classification des Images

Husky or Wolf?



(a) Husky classified as wolf



(b) Explanation

Le modèle détecte la neige au lieu du loup. Il ne peut donc pas être digne de confiance.



Local Interpretable Model-agnostic Explanations

Explication d'une prédiction de classification d'images



(a) Original Image



(b) Explaining *Electric guitar*



(c) Explaining *Acoustic guitar*



(d) Explaining *Labrador*

Explication d'une prédiction de classification d'images réalisée par le réseau de neurones **Inception** de Google. Les trois classes les plus probables prédites sont « **guitare électrique** » ($p = 0,32$), « **guitare acoustique** » ($p = 0,24$) et « **labrador** » ($p = 0,21$).

Le modèle détecte correctement les caractéristiques pertinentes. Il peut donc être considéré comme digne de confiance.





Local Interpretable Model-agnostic Explanations

Intuition derrière LIME

Les modèles linéaires sont facilement interprétables.

Par exemple, si l'on considère :

$$y = w_1x_1 + w_2x_2 + w_3x_3$$





le terme w_ix_i représente la **contribution de la caractéristique x_i** à la prédiction pour une **instance de données spécifique** ; une valeur élevée indique une **forte contribution** à la prédiction.





Local Interpretable Model-agnostic Explanations

Implémentation de LIME en 4 étapes



Local Interpretable Model-agnostic Explanations

Classification de textes

Prediction probabilities




Feature Value

Glucose	98.00
Age	43.00
BMI	34.00
BloodPressure	58.00
Insulin	190.00
SkinThickness	33.00
DiabetesPedigreeFunction	0.43
Pregnancies	6.00



Local Interpretable Model-agnostic Explanations

Exp1: LIME avec des données tabulaires



Local Interpretable Model-agnostic Explanations

Exp2: LIME avec des données textuelles

Sentence to explain

['This', 'is',
'interesting',
'stuff']

Randomly remove
words in new samples

['is', 'interesting',
'stuff']

['This',
'interesting',
'stuff']

['This', 'is',
'stuff']

x_1

Project new samples into the model

$f(x_1, x_2)$

Local linear fit

x_2

['is', 'interesting',
'stuff']

['This', 'is',
'stuff']


['This',
'interesting',
'stuff']

x_1



Local Interpretable Model-agnostic Explanations

Exp3: LIME avec des données d'images



Local Interpretable Model-agnostic Explanations

Exp3: LIME avec des données d'images

LIME appliquée aux images



Original Image



Interpretable
Components


Sous-diviser l'image en composants interprétables



Local Interpretable Model-agnostic Explanations

Exp3: LIME avec des données d'images

Création d'instances perturbées






Nous présentons les super-pixels ayant les poids positifs les plus élevés comme explication, en grisant tous les autres.



Local Interpretable Model-agnostic Explanations

Exp3: LIME avec des données d'images


Que voit le réseau de neurones ?



Nous présentons les super-pixels ayant les poids positifs les plus élevés comme explication, en grisant tous les autres.

Local Interpretable Model-agnostic Explanations

Mathématiques de LIME: Représentation des données



Étant donné que les données tabulaires sont déjà interprétables par les humains, aucune transformation n'est nécessaire



$$x' \in \mathbb{R}^{d'} \longrightarrow x = x' \quad (d = d')$$

Local Interpretable Model-agnostic Explanations

Mathématiques de LIME: Problème d'optimisation

$$\zeta(x) = \arg \min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g)$$

Diagram illustrating the LIME optimization problem:

- $\zeta(x)$: zeta
- x : Predicted instance we want to explain
- G : Family of interpretable models
- f : Complex model being explained
- g : Simple/surrogate model
- π_x : Neighbourhood of x
- $\Omega(g)$: Complexity measure of g

x peut correspondre à une ligne d'un DataFrame.

Gender	Age	Exercise minutes	BMI	Weight
Male	37	125	25	76
Female	66	20	21	53
Female	71	12	28	77



Local Interpretable Model-agnostic Explanations

Mathématiques de LIME: Problème d'optimisation

$$\zeta(x) = \arg \min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g)$$

Diagram illustrating the LIME optimization problem:

- $\zeta(x)$: Predicted instance we want to explain
- G : Family of interpretable models
- f : Complex model being explained
- g : Simple/surrogate model
- π_x : Neighbourhood of x
- $\Omega(g)$: Complexity measure of g

We have 2 loss terms




Local Interpretable Model-agnostic Explanations

Mathématiques de LIME: minimiser L

$$\mathcal{L}(f, g, \pi_x)$$

Il s'agit de la fonction de perte locale « L ».

Nous souhaitons analyser le comportement local de L au voisinage de x .
Ainsi, nous générons des perturbations πx





Local Interpretable Model-agnostic Explanations

Mathématiques de LIME: la forme de $\mathcal{L}$

$$\mathcal{L}(f, g, \pi_x) = \sum_{z \in \mathcal{Z}} \pi_x(z) (f(z) - g(z))^2$$

Complex model
prediction

Simple/surrogate
model prediction




Local Interpretable Model-agnostic Explanations

Mathématiques de LIME: la forme de π

$$\pi_x(z) = \exp(-D(x, z)^2 / \sigma^2)$$

Euclidean distance





Local Interpretable Model-agnostic Explanations

Mathématiques de LIME: Problème d'optimisation

$$\zeta(x) = \arg \min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g)$$

Diagram illustrating the LIME optimization problem:

- $\zeta(x)$: Predicted instance we want to explain
- $g \in G$: Family of interpretable models
- $\mathcal{L}(f, g, \pi_x)$: Complex model being explained (Term 1)
- π_x : Simple/surrogate model
- $\Omega(g)$: Complexity measure of g (Term 2)
- x : Neighbourhood of x

We have 2 loss terms

$$\mathcal{L}(f, g, \pi_x) = \sum_{z \in \mathcal{Z}} \pi_x(z) (f(z) - g(z))^2$$


$$\Omega(g) \text{ LIME uses sparse linear models (K - LASSO)}$$
$$\hat{\beta}_{lasso} = \arg \min_{(\beta_0, \dots, \beta_p) \in \mathbb{R}^n} \left\{ \text{RSS}(\beta) + \lambda \underbrace{\sum_{j=1}^p |\beta_j|}_{\text{Penalty term}} \right\}$$



Local Interpretable Model-agnostic Explanations

Limites de LIME


- **Interprétabilité locale vs globale** : LIME explique des prédictions individuelles, ce qui peut ne pas fournir une vision complète du comportement global du modèle.



Local Interpretable Model-agnostic Explanations

Limites de LIME

- **Hypothèse de linéarité** : LIME ajuste un modèle linéaire pour approximer le processus de décision du modèle original, ce qui peut simplifier excessivement ou représenter de manière inexacte des frontières de décision complexes.



Local Interpretable Model-agnostic Explanations

Limites de LIME


- **Stabilité et cohérence** : L'échantillonnage aléatoire de LIME peut produire des explications différentes pour une même entrée, ce qui soulève des questions de fiabilité.



Local Interpretable Model-agnostic Explanations

Limites de LIME

- **Biais d'échantillonnage** : La génération de données synthétiques par LIME peut ne pas refléter fidèlement la distribution réelle des données, entraînant des explications biaisées ou trompeuses.





Local Interpretable Model-agnostic Explanations

Limites de LIME

- **Interprétabilité locale vs globale** : LIME explique des prédictions individuelles, ce qui peut ne pas fournir une vision complète du comportement global du modèle.
- **Hypothèse de linéarité** : LIME ajuste un modèle linéaire pour approximer le processus de décision du modèle original, ce qui peut simplifier excessivement ou représenter de manière inexacte des frontières de décision complexes.
- **Stabilité et cohérence** : L'échantillonnage aléatoire de LIME peut produire des explications différentes pour une même entrée, ce qui soulève des questions de fiabilité.
- **Biais d'échantillonnage** : La génération de données synthétiques par LIME peut ne pas refléter fidèlement la distribution réelle des données, entraînant des explications biaisées ou trompeuses.





Local Interpretable Model-agnostic Explanations

Référence de LIME

“Why Should I Trust You?” Explaining the Predictions of Any Classifier:
<https://arxiv.org/abs/1602.04938>

