

XAI - Intelligence Artificielle Explicable

Resume Visuel et Pratique

Pr. S. MHAMMEDI

Annee 2025-2026

Table des matières

1	Introduction : Pourquoi XAI?	3
1.1	Le Probleme de la Boite Noire	3
1.2	Solution : XAI	3
1.3	3 Applications Principales	3
1.4	Carte Mentale des Methodes XAI	5
2	Modeles Intrinsequement Interpretables	6
2.1	Regression Lineaire Simple	6
2.2	Arbres de Decision	7
3	Methodes Globales Post-Hoc	8
3.1	PD Plot (Partial Dependence)	8
3.2	ALE Plot vs PD Plot	8
3.3	Courbes ICE (Individual Conditional Expectation)	9
4	SHAP - Valeurs de Shapley	10
4.1	L'Idee Simple	10
4.2	Application ML	11
4.3	Types de Graphiques SHAP	12
5	LIME - Explications Locales Simples	13
5.1	L'Idee en 4 Etapes	13
5.2	LIME pour Images	14
6	Explications Contrefactuelles	15
6.1	L'Idee Simple	15
6.2	Exemple Medical	16
7	Tableau Comparatif Simplifie	17
8	Guide d'Interpretation des Graphiques	18
8.1	Graphique 1 : SHAP Beeswarm	18
8.2	Graphique 2 : PD Plot	18
8.3	Graphique 3 : Arbre de Decision	18

9	Astuces pour l'Examen	19
9.1	Ce qui est VRAIMENT Important	19
9.2	Questions Types	19
9.3	Checklist Avant l'Examen	20
10	Resume Final - Points Cles	21
10.1	Formules Essentielles (minimales)	21
10.2	Enjeux Ethiques - RGPD	21

1 Introduction : Pourquoi XAI ?

1.1 Le Probleme de la Boite Noire

?




POINT CLE

Questions essentielles :

- **Pourquoi** as-tu fait ca ?
- **Quand** puis-je te faire confiance ?
- **Comment** corriger une erreur ?

1.2 Solution : XAI

OK



1.3 3 Applications Principales

1. **Debugage** : Trouver pourquoi le modele se trompe

EXEMPLE: Husky vs Loup

Le modele predit "Loup" pour un Husky

Erreur detectee : Il regarde la **neige** pas l'animal !

Solution : Corriger le dataset

2. **Detection de biais** : Identifier les discriminations

EXEMPLE: Pret bancaire

Prediction : Refus de pret

Biais detecte : Le modele utilise le **sexe** et la **race**!

Solution : Retirer ces variables

3. **Recours** : Donner des solutions


EXEMPLE: Demande de credit refusee

Prediction : Pret refuse

Explication : Salaire trop bas + factures impayees

Solution : Augmenter salaire de 50k\$ + payer factures a temps pendant 3 mois

1.4 Carte Mentale des Methodes XAI



POINT CLE

A retenir :

- **INTRINSEQUE** = Transparent par nature (regression, arbres)
- **GLOBAL** = Explique tout le modele
- **LOCAL** = Explique UNE prediction

2 Modeles Intrinsequement Interpretables

2.1 Regression Lineaire Simple

EXEMPLE: Prix d'une maison

Objectif : Predire le prix d'une maison

Modele :

$$\text{Prix} = 50000 + 200 \times \text{Surface} + 10000 \times \text{Chambres}$$

INTERPRETATION

Lecture :

- Prix de base : **50 000\$**
- Chaque **m²** ajoute **200\$**
- Chaque **chambre** ajoute **10 000\$**

Exemple concret :

- Maison de 100 m² avec 3 chambres
- Prix = $50000 + 200 \times 100 + 10000 \times 3 = 100\ 000\$$

POINT CLE

Avantages :


- + **100% transparent** - On voit tout !
- + **Facile a expliquer** - Meme pour un enfant
- + **Coefficients = Importance**

Inconvenients :

- Relations complexes difficiles a capturer
- Moins performant que les reseaux neuronaux

2.2 Arbres de Decision

EXEMPLE: Titanic - Survie ou mort ?



INTERPRETATION

Regles de decision :

1. Si **Homme** → **Mort** (80% de chances)
2. Si **Femme** ET **1ere/2eme classe** → **Survie** (90%)
3. Si **Femme** ET **3eme classe** → **Survie** (50%)

POINT CLE

Pourquoi c'est genial :


- + **IF-THEN** = Comme notre cerveau !
- + **Visuel** - On voit le chemin de decision
- + **Non-expert friendly**

3 Methodes Globales Post-Hoc

3.1 PD Plot (Partial Dependence)

EXEMPLE: Location de velos selon temperature

Question : Comment la temperature affecte les locations de velos ?



INTERPRETATION

Lecture du graphique :

- A **0°C** : environ 2500 locations
- A **25°C** : environ 5500 locations (MAX!)
- A **35°C** : environ 4200 locations (trop chaud!)

Conclusion : Les gens louent plus quand il fait **25°C** (optimal)

3.2 ALE Plot vs PD Plot

Critere	PD Plot	ALE Plot
Calcul	Moyenne simple	Moyenne des change-ments
Correlation	[-] Probleme si variables liees	[+] Robuste
Utilisation	Variables independantes	Variables correlees
Interpretation	Plus facile	Un peu plus complexe

POINT CLE


Quand utiliser quoi ?

- **PD Plot** : Si vos variables sont **independantes**
- **ALE Plot** : Si vos variables sont **correlees** (ex : temperature et saison)

3.3 Courbes ICE (Individual Conditional Expectation)

EXEMPLE: Effet de la température sur CHAQUE personne

Principe : Au lieu d'une seule courbe moyenne (PD), on trace UNE courbe par personne !



INTERPRETATION

Chaque ligne coloree = une personne differente

Ligne violette epaisse = moyenne = PD Plot


Utilite : Voir si l'effet est different selon les personnes (interactions)

4 SHAP - Valeurs de Shapley

4.1 L'Idee Simple

EXEMPLE: Equipe de Robotique - Partage du Prix

Situation : Equipe de 4 personnes gagne 10 000\$



10 000\$ a partager

Methode SHAP : On teste TOUTES les combinaisons !

- Alice seule : 2000\$
- Alice + Bob : 6000\$ → Contribution Alice = ?
- Alice + Clara : 5000\$ → Contribution Alice = ?
- Alice + Bob + Clara : 8000\$ → Contribution Alice = ?
- ... *et toutes les autres combinaisons*

SHAP calcule la contribution **moyenne equitable** d'Alice dans TOUTES les combinaisons possibles !


4.2 Application ML

EXEMPLE: Prediction Diabete

Patient :

- Age : 45 ans
- Glucose : 180
- BMI : 32
- Exercice : 10 min/jour

Prediction : 85% de risque diabete



INTERPRETATION

Lecture :

- **Glucose (0.45)** : Contribue LE PLUS au risque
- **Age (0.25)** : Contribue moyennement
- **BMI (0.20)** : Contribue un peu
- **Exercice (-0.15)** : REDUIT le risque !

Conseil : Baisser le glucose et faire plus d'exercice !

4.3 Types de Graphiques SHAP

Type	Utilite
Bar Plot	Importance des variables (simple!)
Beeswarm Plot	Importance + Effets (chaque point = une personne)
Waterfall	Decomposition d'UNE prediction etape par etape
Force Plot	Visualisation interactive d'une prediction
Dependence Plot	Comment UNE variable affecte la prediction

POINT CLE

Avantages SHAP :

- + **Mathematiquement juste** (theorie des jeux)
- + **Equitable** - Chaque variable a sa vraie contribution
- + **Marche partout** - Texte, image, tableau

Inconvenient :


- **Calcul long** (teste toutes les combinaisons)

5 LIME - Explications Locales Simples

5.1 L'Idee en 4 Etapes

EXEMPLE: Email Important ou Spam ?

Email original : "J'ai une urgence medicale. Je ne pourrai pas assister a la reunion aujourd'hui."



Perturbations creees :

1. "urgence medicale. assister reunion aujourd'hui." → Important
2. "J'ai une. Je ne pourrai pas." → Pas important
3. "urgence medicale. reunion." → Important

INTERPRETATION

Resultat LIME :


- "urgence medicale" → Contribue a "Important"
- "reunion" → Contribue a "Important"
- "Je ne pourrai" → Moins important

5.2 LIME pour Images

EXEMPLE: Classification Grenouille

Etapes :

1. **Segmenter** l'image en "super-pixels" (petites zones)
2. **Masquer** certains super-pixels (mettre en gris)
3. **Predire** avec le modele
4. **Identifier** les zones importantes



Zone rouge = Ce que le modele regarde pour dire "grenouille" !

POINT CLE

Avantages LIME :

- + **Flexible** - Texte, image, tableau
- + **Model-agnostic** - Marche avec tout
- + **Intuitif** - Facile a comprendre

Inconvenients :

- **Instable** - Peut donner des resultats differents
- **Hypothese lineaire** - Peut simplifier trop

6 Explications Contrefactuelles

6.1 L'Idee Simple

Question :

"Que dois-je changer pour obtenir un resultat different?"

EXEMPLE: Demande de Pret Refusee

Situation actuelle :

Caracteristique	Valeur
Salaire annuel	30 000\$
Dettes	15 000\$
Historique credit	Mauvais
Decision	REFUSE

Contrefactuels (solutions) :

Solution 1 :

Salaire : **45 000\$**

Dettes : 15 000\$

Credit : Mauvais

→ **ACCEPTE**

Solution 2 :

Salaire : 30 000\$

Dettes : **5 000\$**

Credit : **Bon**

→ **ACCEPTE**

INTERPRETATION

Ce que ca dit :

- **Option 1 :** Augmenter salaire a 45k\$
- **Option 2 :** Reduire dettes ET ameliorer credit

Avantage : Vous savez **quoi faire** pour reussir la prochaine fois !

6.2 Exemple Medical

EXEMPLE: Prediction Diabete

Patient Sara :

Caracteristique	Actuel	Contrefactuel
Glucose	195	195
BMI	22	22
Exercise (min)	19	19
Calories	2000	1500
Prediction	Diabete 90%	
		Non-diabete 57%

INTERPRETATION

Action : Reduire les calories de 2000 a 1500 par jour !
C'est **actionnable** et **realiste** !

POINT CLE

Pourquoi c'est genial :

- + **Actionnable** - Dit quoi faire concretement
- + **Recours** - Donne une 2eme chance
- + **Comprehensible** - Comparaison avant/apres

Limitation :

- Parfois **aucune solution** n'existe

7 Tableau Comparatif Simplifie

Quelle Methode Utiliser ?

Methode	Type	Quand ?	Resultat
Regression Lineaire	Intrinseque	Donnees simples	Coefficients clairs
Arbres	Intrinseque	Regles IF-THEN	Chemins de decision
PD Plot	Global	Voir effet global	Courbe d'effet
ALE Plot	Global	Variables correlees	Courbe robuste
SHAP	Local	Contribution juste	Valeurs par variable
LIME	Local	Boite noire	Explication simple
Counterfactuals	Local	Besoin d'action	"Que faire ?"

8 Guide d'Interpretation des Graphiques

8.1 Graphique 1 : SHAP Beeswarm

INTERPRETATION

Comment lire :

1. **Axe Y** : Variables (du plus important en haut)
2. **Axe X** : Impact SHAP (negatif a gauche, positif a droite)
3. **Couleur** : Valeur de la variable (bleu=bas, rouge=haut)

Exemple :

- Temperature : Points **rouges** a droite = *Haute temperature augmente les locations*
- Humidite : Points **rouges** a gauche = *Haute humidite diminue les locations*

8.2 Graphique 2 : PD Plot

INTERPRETATION

Comment lire :

1. **Axe X** : Valeur de la variable
2. **Axe Y** : Prediction moyenne
3. **Courbe** : Montre la relation

Formes courantes :

- **Montante** / : Plus X augmente, plus Y augmente
- **Descendante** \ : Plus X augmente, plus Y diminue
- **Cloche** n : Optimum au milieu
- **Plate** — : Pas d'effet

8.3 Graphique 3 : Arbre de Decision

INTERPRETATION

Comment lire :

1. **Haut** : Racine (premiere question)
2. **Branches** : Chemins selon reponses
3. **Feuilles** : Decisions finales

Exemple interpretation :

- Suivez le chemin de VOTRE cas
- Notez les conditions (ex : "si age $\geq$ 30")
- Arrivez a la prediction finale

9 Astuces pour l'Examen

9.1 Ce qui est VRAIMENT Important

TOP PRIORITES

1. **Comprendre la DIFFERENCE :**
 - Global vs Local
 - Intrinseque vs Post-hoc
 - Model-agnostic vs Model-specific
2. **Savoir QUAND utiliser :**
 - SHAP : Contribution equitable
 - LIME : Explication simple locale
 - Counterfactuals : Actions a faire
 - PD/ALE : Voir effet global
3. **Interpreter les GRAPHIQUES :**
 - Lire axe X et Y
 - Comprendre les couleurs
 - Tirer des conclusions

9.2 Questions Types

Question 1 : "Expliquez la difference entre SHAP et LIME"

Reponse type :

- SHAP : Base theorie des jeux, contribution equitable, toutes combinaisons
- LIME : Modele lineaire local, perturbations, plus simple mais moins stable

Question 2 : "Donnez un exemple d'utilisation de contrefactuels"

Reponse type :

- Pret refuse → Dire quoi changer (salaire, dettes)
- Diabete predit → Dire quelles habitudes modifier
- Donne un RECOURS a la personne

Question 3 : "Interpretez ce graphique..."

Methode :

1. Identifier type graphique (PD, SHAP, Arbre...)
2. Lire axes et legende
3. Decrire la relation (montante, descendante, cloche...)
4. Conclure sur l'impact de la variable

9.3 Checklist Avant l'Examen

Je sais...	OK
Difference Global/Local	☐
Difference Intrinseque/Post-hoc	☐
Quand utiliser SHAP vs LIME	☐
Lire un graphique PD/ALE	☐
Expliquer les contrefactuels avec exemple	☐
Avantages/Inconvenients de chaque methode	☐
Interpreter un arbre de decision	☐
Enjeux ethiques (RGPD, biais)	☐

10 Resume Final - Points Cles

Points Cles XAI

- XAI = Rendre l'IA **comprehensible**
- **Intrinseque** = Transparent des le depart
- **Global** = Tout le modele
- **Local** = Une prediction
- **SHAP** = Contribution juste (theorie des jeux)
- **LIME** = Explication simple et flexible
- **Counterfactuals** = "Que faire pour changer?"

10.1 Formules Essentielles (minimales)

Regression Lineaire :

$$Y = m_0 + m_1x_1 + m_2x_2 + \dots + m_nx_n$$

PD Plot :

$$f_{PD}(x_S) = \mathbb{E}_{x_C}[f(x_S, x_C)]$$

(Moyenne des predictions)

SHAP (idee) :

ϕ_i = Contribution moyenne d'une variable dans toutes les combinaisons

10.2 Enjeux Ethiques - RGPD

- **RGPD** : Droit a l'explication des decisions automatisees
- **Biais** : Detecter les discriminations (sexe, race, age...)
- **Responsabilite** : Tracer qui est responsable en cas d'erreur

BONNE CHANCE !