



جامعة محمد الأول بوجدة
UNIVERSITÉ MOHAMMED PREMIER OUJDA
ⵜⴰⵎⴰⵔⵜ ⵜⴰⵎⴰⵏⵏⴰ ⵜⴰⵖⴰⵔⵜ ⵜⴰⵏⵓⵔⵜ ⵜⴰⵙⴰⵎⴰⵏⵜ

المدرسة الوطنية للذكاء الاصطناعي والرقمنة - بركان
ÉCOLE NATIONALE DE L'INTELLIGENCE ARTIFICIELLE ET DU DIGITAL - BERKANE
ⵎⴰⵔⵓⵏⴰ ⵜⴰⵎⴰⵏⵏⴰ ⵜⴰⵖⴰⵔⵜ ⵜⴰⵏⵓⵔⵜ ⵜⴰⵙⴰⵎⴰⵏⵜ - ⵔⵓⵕⴰⵏ

UNIVERSITÉ MOHAMMED PREMIER ÉCOLE NATIONALE DE L'INTELLIGENCE ARTIFICIELLE ET DU DIGITAL

Rapport de Devoir

Explainable AI Méthodes d'Interprétabilité

PDP, ALE, SHAP, LIME et Contre-factuels
Analyse Approfondie de Modèles ML

Réalisé par :

Mr. Oussama ELHADJI

Encadré par :

Mme. Sajida MHAMMEDI

Année Universitaire 2025–2026

Table des matières

1	Exercice 1 : PDP et ALE sur German Credit	3
1.1	Objectif	3
1.2	Variables Continues	3
1.2.1	Question 1 : PDP pour amount	3
1.2.2	Question 2 : ALE pour amount	3
1.2.3	Question 3 : Effets par quartiles	4
1.2.4	Question 4 : Interactions avec credit_history	5
1.2.5	Question 5 : Quantifier les interactions avec ALE	5
1.3	Variables Catégorielles	6
1.3.1	Question 6 : PDP pour personal_status_sex	6
1.3.2	Question 7 : ALE pour personal_status_sex	6
1.3.3	Question 8 : Analyse de purpose	7
1.3.4	Question 9 : Correction des biais par ALE	7
1.4	Analyse des Interactions	8
1.4.1	Question 10 : ALE 2D pour amount et duration	8
1.4.2	Question 11 : Zones non-additives	9
1.4.3	Question 12 : Interactions et décisions locales vs globales	9
1.4.4	Question 13 : Combinaisons à risque	10
1.4.5	Question 14 : Visualisation simultanée d'ALE multiples	11
1.5	Analyse des Biais et Robustesse	12
1.5.1	Question 15 : Biais de genre et d'emploi	12
1.5.2	Question 16 : Robustesse PDP vs ALE	13
1.5.3	Question 17 : Variables masquant les biais	14
1.5.4	Question 18 : Validation pour décideurs bancaires	15
1.6	Analyse Locale	16
1.6.1	Question 19 : Effets locaux pour individus bad	16
1.6.2	Question 20 : Insights sur décisions individuelles	17
1.6.3	Question 21 : Intégration PDP, ALE et Shapley	18
2	Exercice 2 : SHAP sur FIFA Dataset	20
2.1	Objectif	20
2.2	Chargement et Modélisation	20
2.3	Implémentation SHAP	20
2.3.1	Fonction de valeur marginale	20
2.3.2	KernelSHAP Implementation	20
2.4	Résultats et Interprétation	21
2.4.1	Question 1 : Caractéristique augmentant la probabilité	21
2.4.2	Question 2 : Caractéristique diminuant la probabilité	22
2.4.3	Question 3 : Somme des valeurs SHAP	22
2.4.4	Question 4 : Explication locale et additive	22
2.4.5	Question 5 : Importance locale vs globale	22
2.4.6	Question 6 : Impact de nr_samples	22
2.4.7	Question 7 : Limites de SHAP	22
2.4.8	Question 8 : Interprétation métier	22
3	Exercice 3 : LIME sur Wheat Seeds	23
3.1	Objectif	23

3.2	Partie A : Inspection de la surface de prédiction	23
3.2.1	Question 1 : Surface de prédiction	23
3.2.2	Question 2 : Signification des couleurs	24
3.2.3	Question 3 : Frontières de décision	24
3.2.4	Question 4 : Comportement global	24
3.3	Partie B : Échantillonnage des points	25
3.3.1	Question 5 : Nécessité de l'échantillonnage	25
3.3.2	Question 6 : Influence de la taille de zone	25
3.3.3	Question 7 : Échantillonnage trop éloigné	26
3.4	Partie C : Pondération des points	27
3.4.1	Question 8 : Influence de la distance	27
3.4.2	Question 9 : Surpondération des points proches	27
3.4.3	Question 10 : Représentation visuelle	28
3.5	Partie D : Modèle explicatif local	29
3.5.1	Question 12 : Approximation par l'arbre	29
3.5.2	Question 13 : Régions de fiabilité	29
3.5.3	Question 14 : Dégradation à distance	30
3.5.4	Question 15 : Modèle global vs explication locale	30
3.6	Analyse critique (Questions 16-20)	30
3.6.1	Question 16 : Facilitation de la compréhension	31
3.6.2	Question 17 : Cas trompeurs	31
3.6.3	Question 18 : Impact du nombre de points	31
3.6.4	Question 19 : Position et frontières	31
3.6.5	Question 20 : Deux limites de LIME	31
4	Exercice 4 : Contre-factuels What-If	32
4.1	Objectif	32
4.2	Implémentation	32
4.3	Résultats	32
4.4	Partie b : Attributs et Avantages/Inconvénients	33
4.5	Questions d'Interprétation	33
4.5.1	Question 1 : Modifications des caractéristiques	33
4.5.2	Question 2 : Caractéristiques les plus modifiées	33
4.5.3	Question 3 : Sensibilité du modèle	34
5	Conclusion Générale	35
5.1	Enseignements Clés	35
5.2	Recommandations Pratiques	35
5.3	Limites et Perspectives	35

1 Exercice 1 : PDP et ALE sur German Credit

1.1 Objectif

Interpréter un modèle Random Forest sur le dataset German Credit en utilisant les méthodes PDP (Partial Dependence Plot) et ALE (Accumulated Local Effects) pour analyser les effets globaux et locaux des variables.

1.2 Variables Continues

1.2.1 Question 1 : PDP pour amount

Résultat : Le PDP révèle une relation non-linéaire entre le montant du crédit et la probabilité de bon crédit. La probabilité augmente de 0.65 à 0.78 pour les montants entre 0 et 3000, puis diminue jusqu'à 0.68 pour les montants supérieurs à 8000.




FIGURE 1 – PDP pour la variable amount

Interprétation : La non-linéarité suggère que les crédits modérés (2000-4000) sont perçus comme plus sûrs, tandis que les très gros montants augmentent le risque.

1.2.2 Question 2 : ALE pour amount

Résultat : L'ALE montre une tendance plus stable que le PDP, avec une augmentation progressive jusqu'à 4000, puis une légère diminution. L'effet maximal est de +0.08 à 4000.




FIGURE 2 – ALE pour la variable amount et comparaison avec PDP

Différence avec PDP : L'ALE corrige le biais dû aux corrélations, donnant une mesure plus fidèle de l'effet causal isolé du montant.

1.2.3 Question 3 : Effets par quartiles




FIGURE 3 – Comparaison des effets moyens par quartiles

Résultat : Pour **amount**, l'effet varie fortement entre quartiles (Q1 : +0.02, Q4 : -0.03). Pour **duration**, l'effet négatif s'intensifie avec les quartiles (Q1 : -0.01, Q4 : -0.08), confirmant qu'une durée longue augmente le risque.

1.2.4 Question 4 : Interactions avec `credit_history`



FIGURE 4 – Interaction entre `amount` et `credit_history`

Résultat : Le PDP est biaisé car `credit_history` et `amount` sont corrélés. Les bons historiques tendent vers des montants modérés, ce qui surévalue l'effet apparent du montant dans le PDP. L'ALE isole correctement cet effet.

1.2.5 Question 5 : Quantifier les interactions avec ALE

Méthode : Calculer l'ALE 2D et mesurer l'écart à l'additivité. Un score d'interaction de 0.042 indique une interaction modérée entre `amount` et `duration`.

1.3 Variables Catégorielles

1.3.1 Question 6 : PDP pour personal_status_sex




FIGURE 5 – PDP pour personal_status_sex

Limites observées : Le PDP montre des effets moyens pour chaque catégorie, mais masque les variations locales. Les catégories rares (A92) ont des intervalles de confiance larges, rendant l'estimation peu fiable.

1.3.2 Question 7 : ALE pour personal_status_sex




FIGURE 6 – ALE pour personal_status_sex

Différence : L'ALE donne des effets plus contrastés. La catégorie A93 (homme marié/veuf) montre un effet positif de +0.12, tandis que le PDP ne révélait que +0.08, démontrant que l'ALE corrige mieux les corrélations avec d'autres variables.

1.3.3 Question 8 : Analyse de purpose




FIGURE 7 – Analyse détaillée de la variable purpose

Résultat :

- **Effet positif** : A43 (voiture neuve, +0.15)
 - **Effet négatif** : A410 (autres, -0.18), A45 (réparations, -0.12)
- Les crédits pour voitures neuves sont associés à une meilleure solvabilité.

1.3.4 Question 9 : Correction des biais par ALE

Explication : L'ALE calcule les changements locaux de prédiction en conditionnant sur les valeurs observées dans chaque strate, éliminant l'effet de composition du PDP. Par exemple, si les hommes mariés demandent plus de crédits auto, le PDP surévalue l'effet du statut marital, alors que l'ALE isole correctement l'effet de chaque variable.

1.4 Analyse des Interactions

1.4.1 Question 10 : ALE 2D pour amount et duration




FIGURE 8 – ALE 2D montrant l'interaction entre amount et duration

Résultat : L'ALE 2D révèle des zones d'interaction forte (rouge) où l'effet combiné dépasse la somme des effets individuels.

1.4.2 Question 11 : Zones non-additives




FIGURE 9 – Identification des zones non-additives

Interprétation : Dans la zone `amount > 5000` et `duration > 30` mois, l'effet conjoint est fortement négatif (-0.22), indiquant que le modèle perçoit cette combinaison comme particulièrement risquée.

1.4.3 Question 12 : Interactions et décisions locales vs globales




FIGURE 10 – Comparaison locale vs globale

Résultat : L'identification des interactions permet d'expliquer pourquoi deux individus avec des valeurs similaires sur une variable peuvent recevoir des prédictions différentes selon les autres variables. Cela aide à justifier les décisions individuelles aux clients.

1.4.4 Question 13 : Combinaisons à risque




FIGURE 11 – Interaction credit_history × personal_status_sex

Résultat : La combinaison credit_history=A34 (historique critique) + personal_status_sex=A92 (femme divorcée) montre un risque élevé avec une probabilité de bon crédit de seulement 42%.

1.4.5 Question 14 : Visualisation simultanée d'ALE multiples




FIGURE 12 – Dashboard multi-ALE pour détecter les interactions complexes

Stratégie : Un dashboard avec des matrices de corrélation d'effets ALE entre toutes les paires de variables permet de repérer visuellement les interactions fortes. Les heatmaps facilitent l'identification rapide des combinaisons à analyser en profondeur.

1.5 Analyse des Biais et Robustesse

1.5.1 Question 15 : Biais de genre et d'emploi




FIGURE 13 – Analyse des biais potentiels

Résultat : L'ALE révèle un biais de genre : les femmes seules (A92) ont un effet négatif de -0.08, tandis que les hommes mariés (A93) ont +0.12. Pour l'emploi, les catégories "sans emploi" montrent un effet négatif de -0.15.

1.5.2 Question 16 : Robustesse PDP vs ALE




FIGURE 14 – Comparaison de robustesse PDP vs ALE

Discussion : L’ALE montre des intervalles de confiance plus étroits et des estimations plus stables, confirmant sa supériorité en présence de corrélations. Les conclusions sont plus robustes avec ALE.

1.5.3 Question 17 : Variables masquant les biais




FIGURE 15 – Détection de biais masqués par PDP

Résultat : Les variables `employment_duration` et `age` masquent des biais dans le PDP. L'effet apparent de l'âge dans le PDP disparaît partiellement dans l'ALE, révélant que c'était un artefact dû à la corrélation avec la durée d'emploi.

1.5.4 Question 18 : Validation pour décideurs bancaires

PROTOCOLE DE VALIDATION ALE POUR DÉCIDEURS BANCAIRES			
1. VALIDATION TECHNIQUE			
Test	Objectif	Critère de succès	Résultat
Bootstrap Stability	Robustesse statistique	CV < 10%	✓ PASSE
Sensitivity Analysis	Indépendance hyperparamètres	p > 0.90	⚠ À TESTER
Hold-out Validation	Généralisation	Δ < 0.02	✓ PASSE
Convergence PDP-ALE	Détection biais corrélation	PDP-ALE < 0.05	✓ PASSE
H-statistic Computation	Quantification interactions	H ² calculable	✓ PASSE

QUESTIONS POUR RISK MANAGERS:		2. VALIDATION MÉTIER
A. Cohérence avec l'expérience:	☐ Les effets ALE correspondent-ils aux patterns de défaut observés? ☐ Les catégories à haut risque sont-elles cohérentes avec le portefeuille?	
B. Plausibilité causale:	☐ Chaque effet identifié a-t-il une explication économique? ☐ Y a-t-il des effets contre-intuitifs nécessitant investigation?	
C. Conformité réglementaire:	☐ Le modèle respecte-t-il les directives EBA/BCBS 239? ☐ Les variables utilisées sont-elles légalement acceptables? ☐ La documentation est-elle suffisante pour un audit?	
D. Actionnabilité:	☐ Les insights ALE peuvent-ils guider des décisions opérationnelles? ☐ Les seuils de risque sont-ils clairement identifiables?	

STRUCTURE DU RAPPORT POUR COMITÉ DE DIRECTION:		4. PROTOCOLE DE PRÉSENTATION AUX DÉCIDEURS
1. RÉSUMÉ EXÉCUTIF (1 slide)	3-5 insights clés en langage business - Focus sur l'actionnabilité: "Que devons-nous faire différemment?" - Quantification de l'impact: "Réduction du risque de X%"	
2. METHODOLOGIE SIMPLIFIÉE (2 slides)	- Explication visuelle de l'ALE: "Comment le modèle prend ses décisions" - Avantages vs PDP: "Pourquoi cette méthode est plus fiable" - Garanties statistiques: "Niveau de confiance de nos conclusions"	
3. RÉSULTATS PAR FEATURE (3-5 slides)	- Un graphique ALE par variable importante - Annotations en langage métier (éviter jargon technique) - Zones de risque colorées (vert/orange/rouge) - Recommandations d'action par zone	
4. ANALYSE DE Biais (2 slides)	- Résultats audit fairness (genre, emploi) - Comparaison avec benchmarks sectoriels - Plan d'action si biais détecté	
5. VALIDATION ET ROBUSTESSE (1 slide)	- Checklist des tests réussis - Limites et zones d'incertitude - Plan de monitoring continu	
6. RECOMMANDATIONS STRATÉGIQUES (1 slide)	- Ajustements de politique de crédit - Ségments à cibler/éviter - KPIs de suivi	
BONNES PRATIQUES: ✓ Utiliser des analogies (ex: "L'ALE est comme un GPS qui montre le chemin sans raccourcis trompeurs") ✓ Présenter des cas concrets (ex: "Pour un emprunteur type avec 5000€ sur 24 mois...") ✓ Préparer des Q&A anticipées (ex: "Pourquoi ce résultat diffère de notre intuition?") ✓ Fournir un glossaire en annexe ✓ Éviter les équations mathématiques ✓ Ne pas montrer de code ✓ Limiter les acronymes techniques		

MÉTRIQUES: 3. AUDIT FAIRNESS	
Disparate Impact:	0.929
Statistical Parity:	0.051
Equal Opportunity:	À calculer
Calibration Gap:	0.039
SEUILS:	
• Disp. Impact > 0.80	
• Stat. Parity < 0.05	

FIGURE 16 – Protocole de validation des interprétations ALE

Méthode :

1. Tester sur sous-échantillons (bootstrap) pour vérifier la stabilité
2. Comparer avec domaine métier (expertise bancaire)
3. Valider avec tests de sensibilité (perturbations contrôlées)
4. Documenter les limites et incertitudes

1.6 Analyse Locale

1.6.1 Question 19 : Effets locaux pour individus bad

ANALYSE LOCALE: Effets PDP & ALE pour 3 individus BAD




FIGURE 17 – Effets locaux ALE et PDP pour 3 individus bad

Résultat : Pour l'individu 1 (bad), l'ALE local montre que `duration=36` mois contribue -0.15, et `amount=8000` contribue -0.08. Le PDP sous-estime ces effets négatifs.

1.6.2 Question 20 : Insights sur décisions individuelles





FIGURE 18 – Comparaison effets locaux vs globaux

Insights : L'analyse locale révèle que certains individus ont des combinaisons de features particulièrement défavorables non visibles dans l'analyse globale. Par exemple, l'individu 2 a un bon `amount` mais une mauvaise `duration`, expliquant sa classification bad.

1.6.3 Question 21 : Intégration PDP, ALE et Shapley

FRAMEWORK HIÉRARCHISÉ: PDP + ALE + SHAP



COMPARAISON DES MÉTHODES

Méthode	Portée	Corrélations	Coût	Additivité	Usage
PDP	Globale	X Biased	Faible	X Non	Exploration
ALE	Globale	✓ Robuste	Moyen	✓ Oui	Validation
ALE 2D	Globale	✓ Robuste	Élevé	✓ Oui	Interactions
SHAP	Locale	✓ Robuste	Très élevé	✓ Oui	Explication

CAS D'USAGE PAR MÉTHODE:

PDP:

- Reporting exécutif (tendances générales)
- Feature screening (identifier Top 5)
- Communication grand public

ALE:

- Audit réglementaire (biais-free)
- Documentation technique
- Validation de modèles

ALE 2D:

- Optimisation de politiques
- Détection de sous-groupes à risque
- Pricing segmenté

SHAP:

- Dossiers clients individuels
- Contestations de décisions
- RGPD "droit à l'explication"

ARBRE DE DÉCISION:

Question 1: But de l'analyse?

- Exploration → PDP
- Validation → ALE
- Explication locale → SHAP

Question 2: Corrélations présentes?

- Oui ($n^2 > 0.06$) → ALE obligatoire
- Non → PDP acceptable

Question 3: Interactions suspectées?

- Oui → ALE 2D + H-statistic
- Non → ALE 1D suffisant

Question 4: Budget computationnel?

- Faible → PDP uniquement
- Moyen → PDP + ALE
- Élevé → PDP + ALE + SHAP

Question 5: Audience?

- Exécutifs → PDP (visuel)
- Risk/Audit → ALE (robuste)
- Clients → SHAP (individuel)

EXEMPLE D'INTÉGRATION: Analyse d'un refus de crédit

ETAPE 1: CONTEXTE GLOBAL (ALE)

- Top 3 features: duration (std=0.88), amount (std=0.87), credit history (std=0.86)
- Interactions: duration*amount (H=0.29) → Zone rouge: <48 mois * >8800€

ETAPE 2: DÉCISION INDIVIDUELLE (SHAP)

Client X: 45 ans, 12000€ sur 48 mois, chômeur
Prédiction: Pileux = 0.32 → REFUS

Contributions SHAP:

- Baseline: 0.78
- Amount (12000€): -0.18 → Cohérent avec ALE (zone rouge)
- Duration (48mo): -0.15 → Cohérent avec ALE (effet négatif)
- Unemployed: -0.18 → ALE employment duration=0.837 (amplifié localement)
- Age (45 ans): -0.05 → ALE aged > 45 ans (neutre)
- Prédiction: 0.32

ETAPE 3: VALIDATION CROISÉE

- SHAP amount: -0.18 vs ALE local (bin >10000€) = -0.15 → ✓ Cohérent
- SHAP duration: -0.15 vs ALE local (bin >48mo) = -0.17 → ✓ Cohérent
- Interaction SHAP implicite: -0.18 + -0.15 = -0.33 vs ALE 2D = -0.24 → Écart de 0.09
- Investigation: Le modèle pénalise PLUS localement que l'interaction moyenne globale

ETAPE 4: RAPPORT POUR DÉCIDEUR

"Monsieur X, votre demande a été refusée pour les raisons suivantes:

- Montant élevé (12000€): Votre demande dépasse le seuil de risque acceptable pour des crédits de cette durée (18% de probabilité d'approbation).
- Durée longue (48 mois): Les crédits au-delà de 36 mois présentent un risque accru de défaut (15% de probabilité).
- Situation d'emploi: Votre statut actuel réduit la probabilité d'approbation de 10%.

Recommandation: Réduire le montant à 6800€ sur 24 mois augmenterait vos chances à 65%."

FIGURE 19 – Framework intégré PDP-ALE-SHAP

Stratégie hiérarchisée :

1. Niveau 1 - Global : Utiliser ALE pour identifier les variables importantes et

leurs effets moyens

2. **Niveau 2 - Interactions** : Calculer ALE 2D pour les paires de variables corrélées
3. **Niveau 3 - Local** : Appliquer SHAP pour expliquer chaque décision individuelle
4. **Niveau 4 - Validation** : Comparer avec PDP pour détecter d'éventuels biais cachés

2 Exercice 2 : SHAP sur FIFA Dataset

2.1 Objectif

Calculer les valeurs de Shapley pour interpréter les prédictions d'un modèle Random Forest sur le dataset FIFA, en implémentant la méthode KernelSHAP.

2.2 Chargement et Modélisation

Tâche : Prédire la probabilité d'obtenir "Man of the Match" avec une Random Forest.

```

1 dataset = Dataset("fifa", [4, 5], [20],
2                     normalize=True, categorical=True)
3 (X_train, y_train), (X_test, y_test) = dataset.get_data()
4
5 model_RF = RandomForestClassifier(n_estimators=100,
6                                   random_state=42)
7 model_RF.fit(X_train, y_train)
8 accuracy = model_RF.score(X_test, y_test)
9 # Accuracy: 0.867

```

Listing 1 – Chargement des données FIFA

2.3 Implémentation SHAP

2.3.1 Fonction de valeur marginale

```

1 def m_vfunc(x, coalition, model, X_train):
2     n_samples = 1000
3     predictions = []
4
5     for _ in range(n_samples):
6         x_sample = x.copy()
7         for j in range(len(x)):
8             if j not in coalition:
9                 random_idx = np.random.randint(len(X_train))
10                x_sample[j] = X_train[random_idx, j]
11
12            pred = model.predict_proba([x_sample])[0][1]
13            predictions.append(pred)
14
15     return np.mean(predictions)

```

Listing 2 – Implémentation m_vfunc

2.3.2 KernelSHAP Implementation

```

1 def shap_weights(mask):
2     M = len(mask)
3     z = np.sum(mask)
4     if z == 0 or z == M:

```

```

5         return 1e10
6         return (M - 1) / (comb(M, z) * z * (M - z))
7
8     def kernel_shap(obs, X, nr_samples, predict):
9         # Generate samples and compute weights
10        masks, predictions, weights = shap_data(
11            obs, X, nr_samples, predict)
12
13        # Fit weighted linear regression
14        model = LinearRegression()
15        model.fit(masks, predictions, sample_weight=weights)
16
17        return model.coef_

```

Listing 3 – Implémentation KernelSHAP

2.4 Résultats et Interprétation




FIGURE 20 – Analyse des valeurs SHAP pour une instance FIFA

2.4.1 Question 1 : Caractéristique augmentant la probabilité

Réponse : Ball Possession % contribue le plus positivement (+0.082), indiquant qu'une possession élevée augmente fortement les chances d'avoir le Man of the Match.

2.4.2 Question 2 : Caractéristique diminuant la probabilité

Réponse : **Attempts** contribue négativement (-0.045), suggérant que pour cette instance, un nombre d'attempts inférieur à la moyenne réduit la probabilité.

2.4.3 Question 3 : Somme des valeurs SHAP

Explication : La prédiction finale s'obtient par :

$$\text{Prédiction} = \text{Valeur moyenne} + \sum_i \phi_i$$

où ϕ_i sont les valeurs SHAP. Cette décomposition additive permet de quantifier la contribution exacte de chaque feature au passage de la prédiction moyenne (baseline) à la prédiction individuelle.

2.4.4 Question 4 : Explication locale et additive

Réponse : SHAP fournit une explication locale car les valeurs sont calculées pour une instance spécifique. L'additivité garantit que la somme des contributions égale l'écart à la baseline, permettant une décomposition complète et cohérente de la prédiction.

2.4.5 Question 5 : Importance locale vs globale

Réponse : L'importance locale SHAP peut différer de l'importance globale (feature importance) car elle dépend des valeurs spécifiques de l'instance. Par exemple, **Ball Possession** peut être globalement la plus importante, mais pour une instance avec possession moyenne, son SHAP sera faible.

2.4.6 Question 6 : Impact de nr_samples

Réponse : Avec 100 échantillons, le temps de calcul est de 2.3s mais la variance des estimations est élevée (± 0.02). Avec 1000 échantillons, le temps monte à 18.5s mais la variance chute à ± 0.005 , améliorant la stabilité.

2.4.7 Question 7 : Limites de SHAP

1. **Coût computationnel :** Pour un Random Forest avec de nombreuses features, le calcul de toutes les coalitions devient prohibitif
2. **Corrélations :** SHAP peut produire des valeurs contre-intuitives si les features sont fortement corrélées, car les coalitions artificielles violent les dépendances naturelles

2.4.8 Question 8 : Interprétation métier

- **Ball Possession (+0.082) :** Dans le football, une équipe dominant la possession contrôle le jeu, créant plus d'opportunités. Un joueur de l'équipe dominante a plus de chances d'être décisif, d'où l'attribution du Man of the Match.
- **Attempts (-0.045) :** Un faible nombre de tentatives peut indiquer une équipe défensive ou inefficace offensivement. Même avec possession, si l'équipe ne tire pas, elle crée moins d'actions spectaculaires justifiant le Man of the Match.

3 Exercice 3 : LIME sur Wheat Seeds

3.1 Objectif

Implémenter LIME (Local Interpretable Model-agnostic Explanations) pour interpréter un Support Vector Machine avec kernel RBF sur le dataset Wheat Seeds (classification 3 classes, projection 2D sur area et perimeter).

3.2 Partie A : Inspection de la surface de prédiction




FIGURE 21 – Surface de prédiction du SVM et distribution des classes

3.2.1 Question 1 : Surface de prédiction

Réponse : La surface représente les régions de décision du SVM dans l'espace 2D formé par les features area et perimeter. Chaque point du plan est coloré selon la classe prédite (3 variétés de blé).

3.2.2 Question 2 : Signification des couleurs

Réponse : Les trois couleurs (jaune, violet, cyan) correspondent aux trois classes de graines de blé. Les zones uniformes indiquent des régions où le modèle est certain, tandis que les transitions révèlent les frontières entre classes.

3.2.3 Question 3 : Frontières de décision

Réponse : Les frontières courbes séparant les couleurs sont les surfaces de décision du SVM. Leur forme non-linéaire résulte du kernel RBF qui capture les relations complexes entre les features. Les frontières suivent les densités naturelles des données.

3.2.4 Question 4 : Comportement global

Réponse : Le SVM crée des régions compactes et bien séparées. Les trois classes sont clairement distinctes dans cet espace 2D. L'accuracy de 84% confirme que cette projection capture l'essentiel de la structure discriminante du problème.

3.3 Partie B : Échantillonnage des points




FIGURE 22 – Échantillonnage de points autour de l’instance d’intérêt

3.3.1 Question 5 : Nécessité de l’échantillonnage

Réponse : L’échantillonnage génère un dataset local autour du point d’intérêt pour entraîner le modèle explicatif simple (arbre de décision). Sans points échantillonnés, on ne peut pas apprendre comment le SVM se comporte dans ce voisinage.

3.3.2 Question 6 : Influence de la taille de zone

Réponse : Une zone trop petite donne une explication très locale mais instable, avec peu de points pour entraîner l’arbre. Une zone trop large dilue l’explication en incluant des comportements éloignés qui ne sont plus pertinents pour comprendre la décision au point d’intérêt.




FIGURE 23 – Comparaison échantillonnage local vs global

3.3.3 Question 7 : Échantillonnage trop éloigné

Réponse : Si les points sont trop loin, l’arbre apprendra le comportement global du SVM plutôt que local. L’explication perdra sa pertinence car le SVM change de comportement selon la région, comme le montrent les différentes orientations des frontières.

3.4 Partie C : Pondération des points

LIME - Pondération avec noyau exponentiel (Wheat Seeds)




FIGURE 24 – Pondération exponentielle des points échantillonnés

3.4.1 Question 8 : Influence de la distance

Réponse : La distance influence le poids exponentiellement selon $w = \sqrt{\exp(-d^2/\sigma^2)}$. Un doublement de distance réduit drastiquement le poids. Les graphiques montrent une correspondance parfaite entre les points échantillonnés et la courbe théorique.

3.4.2 Question 9 : Surpondération des points proches

Réponse : Les points proches reçoivent un poids élevé car ils représentent mieux le comportement local du SVM. LIME cherche à approximer le modèle dans un voisinage restreint, pas globalement. Concentrer les poids sur les voisins immédiats réduit le biais d'estimation.




FIGURE 25 – Analyse comparative des kernel widths

3.4.3 Question 10 : Représentation visuelle

Réponse : La taille des marqueurs reflète les poids. Pour $kw=0.1$, tous les points sont minuscules (poids quasi-nuls). Pour $kw=1.0$, on observe un contraste net avec de gros cercles près du point d'intérêt. Le zoom local montre une gradation concentrique parfaite.

3.5 Partie D : Modèle explicatif local




FIGURE 26 – Arbres de décision explicatifs vs SVM

3.5.1 Question 12 : Approximation par l'arbre

Réponse : L'arbre crée des régions rectangulaires (splits parallèles aux axes) pour approximer les frontières courbes du SVM. Pour $kw=1.0$, l'arbre atteint 84% de fidélité avec 8 feuilles. Les règles capturent le comportement local sous forme de conditions simples.

3.5.2 Question 13 : Régions de fiabilité

Réponse : L'approximation est fiable dans un rayon de 0.5-1.0 autour du point d'intérêt, comme le montre la carte de désaccord (zones vertes). Au-delà de rayon 2.0, la fidélité chute car les frontières du SVM changent d'orientation. Les désaccords se concentrent aux frontières inter-classes.

3.5.3 Question 14 : Dégradation à distance

Réponse : L'approximation échoue loin du point car (1) les poids exponentiels deviennent négligeables, (2) le SVM change de géométrie locale selon la région, et (3) l'arbre applique une règle globale rigide inadaptée aux variations spatiales du modèle.

3.5.4 Question 15 : Modèle global vs explication locale

Réponse : Le SVM global optimise sur toutes les données avec des frontières complexes partout. L'explication locale utilise seulement les points pondérés autour de x et

sacrifie la fidélité globale pour la simplicité. L'arbre donne 8 règles lisibles alors que le SVM est un modèle complexe.

3.6 Analyse critique (Questions 16-20)




FIGURE 27 – Analyse de fidélité et désaccords

3.6.1 Question 16 : Facilitation de la compréhension

Réponse : Les graphiques offrent trois niveaux : (1) surfaces colorées montrant la logique spatiale, (2) superposition SVM-arbre révélant les zones de fidélité, (3) règles textuelles donnant des décisions actionnables. On voit immédiatement où l'explication est valide.

3.6.2 Question 17 : Cas trompeurs

Réponse : Les explications peuvent tromper quand : (1) $kw=0.1$ affiche 100% de fidélité locale mais seulement 59% globale, (2) les frontières visualisées partout suggèrent une validité globale inexistante, (3) l'instabilité est cachée où des points adjacents reçoivent des explications différentes.

3.6.3 Question 18 : Impact du nombre de points

Réponse : Avec 50 points, variance élevée et couverture incomplète. Avec 500 points, la fidélité monte de 84% à 85% et les zones de désaccord sont mieux identifiées. Au-delà,

le gain est marginal car la complexité de l'arbre plafonne.

3.6.4 Question 19 : Position et frontières

Réponse : Le point actuel est en zone stable (classe 0), donnant une fidélité locale de 84%. S'il était sur une frontière, la fidélité chuterait car l'arbre ne peut pas reproduire les décisions probabilistes du SVM. Les cercles concentriques montrent comment la zone d'influence capture progressivement les frontières.

3.6.5 Question 20 : Deux limites de LIME

1. **Incapacité à capturer la non-linéarité au-delà du rayon effectif :** Même avec $kw=2.0$, le taux d'erreur reste à 15% dans les zones éloignées. C'est intrinsèque car LIME suppose une approximation locale simple.
2. **Absence de méthode automatique pour le kernel width :** Les résultats varient de 59% à 85% de fidélité selon ce paramètre, sans procédure de sélection optimale contrairement à la cross-validation classique.

4 Exercice 4 : Contre-factuels What-If

4.1 Objectif

Implémenter la méthode What-If pour générer des explications contre-factuelles en trouvant le point de données réel le plus proche ayant une prédiction différente.

4.2 Implémentation

```

1 def generate_whatif(x_interest, model, dataset):
2     y_interest = model.predict(x_interest)[0]
3     y_pred = model.predict(dataset)
4
5     # Extraire points avec pr diction dif f e r e n t e
6     mask_different = (y_pred != y_interest)
7     X_different = dataset[mask_different]
8
9     if len(X_different) == 0:
10         return None
11
12     # Calculer distances de Gower
13     distances = gower.gower_matrix(x_interest,
14                                     X_different)[0]
15
16     # Retourner le plus proche
17     closest_idx = np.argmin(distances)
18     counterfactual = X_different[closest_idx].reshape(1, -1)
19
20     return counterfactual

```

Listing 4 – Génération de contre-factuels

4.3 Résultats

```

1 --- ORIGINAL INSTANCE ---
2 Values: [5.1 3.5 1.4 0.2]
3 Prediction: 0 (Class Setosa)
4 Probabilities: [1. 0.]
5
6 --- COUNTERFACTUAL ---
7 Values: [5.1 2.5 3.0 1.1]
8 Prediction: 1 (Class Versicolor)
9 Probabilities: [0. 1.]
10
11 --- FEATURE CHANGES ---
12 sepal length      : 5.100 -> 5.100 (  =+0.000, +0.0%)
13 sepal width       : 3.500 -> 2.500 (  =-1.000, -28.6%)
14 petal length      : 1.400 -> 3.000 (  =+1.600, +114.3%)
15 petal width       : 0.200 -> 1.100 (  =+0.900, +450.0%)
16

```

```

17 Gower distance: 0.7500
18
19 --- MINIMALITY ---
20 NON-MINIMAL
21 Unnecessary features: All features
22 Necessary features: None

```

Listing 5 – Résultats d'exécution

4.4 Partie b : Attributs et Avantages/Inconvénients

Attributs satisfaits :

- **Validité** : Le contre-factuel est un point réel du training set, garantissant une prédiction valide
- **Proximité** : Distance de Gower minimale (0.75)
- **Sparsité** $\sim$: 3 features sur 4 modifiées

Attributs NON satisfaits :

- **Parcimonie/Minimality** : Toutes les features sont marquées comme non nécessaires
- **Actionabilité** : Augmenter petal width de 450% n'est pas réaliste
- **Diversité** : Un seul contre-factuel généré

Avantages :

- Implémentation simple (nearest neighbor)
- Toujours valide (points réels)
- Calcul rapide
- Gower distance gère données mixtes

Inconvénients :

- Explications non-minimales
- Limité aux points existants
- Pas de garantie d'actionabilité
- Manque de diversité
- Peut être éloigné si données sparses

4.5 Questions d'Interprétation

4.5.1 Question 1 : Modifications des caractéristiques

Réponse : Le contre-factuel modifie 3 features : sepal width diminue de 28.6% (3.5 $\rightarrow$ 2.5), petal length augmente de 114.3% (1.4 $\rightarrow$ 3.0), et petal width augmente de 450% (0.2 $\rightarrow$ 1.1). Seul sepal length reste constant. Ces changements transforment une fleur avec petits pétales (setosa) en une fleur avec pétales plus développés (versicolor).

4.5.2 Question 2 : Caractéristiques les plus modifiées

Réponse : En termes relatifs, petal width change le plus (+450%), suivi de petal length (+114.3%). En valeur absolue, petal length ($=+1.6$) dépasse petal width ($=+0.9$). Les dimensions des pétales sont les facteurs déterminants pour atteindre la classe opposée.

4.5.3 Question 3 : Sensibilité du modèle

Réponse : Le modèle est hautement sensible aux dimensions des pétales et insensible à sepal length. Le test de minimalité révèle que le modèle utilise des règles d'interaction complexes nécessitant des changements simultanés multiples. Les pourcentages élevés (+450%) suggèrent que l'instance originale est loin de la frontière de décision. L'accuracy parfaite (100%) indique un possible surapprentissage.

5 Conclusion Générale

Ce devoir a permis d'explorer quatre méthodes majeures d'Explainable AI sur des cas concrets :

5.1 Enseignements Clés

PDP vs ALE : L'ALE corrige systématiquement les biais du PDP en présence de corrélations, fournissant des estimations causales plus fidèles. L'analyse sur German Credit a révélé des biais de genre masqués par le PDP.

SHAP : Les valeurs de Shapley offrent une décomposition additive et équitable des contributions, mais leur coût computationnel et leur sensibilité aux corrélations limitent leur usage sur de gros datasets.

LIME : L'approximation locale par modèle simple est intuitive mais limitée spatialement. La fidélité dépend fortement du kernel width, sans méthode optimale de sélection.

Contre-factuels : L'approche What-If est simple mais produit des explications non-minimales et parfois non-actionnables. Des méthodes plus sophistiquées (DiCE, MOC) sont nécessaires pour des applications critiques.

5.2 Recommandations Pratiques

Pour une analyse complète d'un modèle :

1. **Niveau global** : Commencer par ALE pour identifier les variables importantes et leurs effets moyens
2. **Niveau interactions** : Calculer ALE 2D pour les paires de variables corrélées
3. **Niveau local** : Utiliser SHAP ou LIME pour expliquer des décisions individuelles
4. **Validation** : Confronter systématiquement PDP et ALE pour détecter les biais cachés

5.3 Limites et Perspectives

Les méthodes XAI actuelles présentent des limites : coût computationnel élevé, sensibilité aux corrélations, stabilité variable. Les développements futurs devront intégrer des contraintes de causalité, d'équité et d'actionabilité pour des explications véritablement utiles aux décideurs.