

Atelier : Application des ALE (Accumulated Local Effects)

1. Introduction

Dans cet atelier, nous allons appliquer la méthode **ALE (Accumulated Local Effects)** à l'aide de la bibliothèque [Alibi](#), qui fournit plusieurs techniques d'**Explainable AI (XAI)**. Nous nous intéressons particulièrement aux fonctions :

- **ALE**
- **plot_ale**

L'objectif est :

- de comprendre comment appliquer les ALE,
- de savoir interpréter les graphiques,
- d'apprendre à combiner plusieurs ALE,
- et d'étudier l'effet du choix de la taille des intervalles.

2. Importation des bibliothèques

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.ensemble import RandomForestRegressor
from alibi.explainers import ALE
from alibi.explainers import plot_ale
```

3. Jeu de données

Nous utilisons le jeu de données [Abalone](#) (UCI) pour prédire le nombre d'anneaux (rings), qui représente l'âge de l'abalone.

3.1 Chargement des données

```
data = pd.read_csv("../data/abalone.data",
                  names=["sex", "length", "diameter", "height", "whole weight",
                        "shucked weight", "viscera weight", "shell weight", "rings"])
```

3.2 Sélection de la cible et des variables explicatives

```
y = data["rings"]
X = data[["sex", "length", "height", "shucked weight",
         "viscera weight", "shell weight"]]
```

Remarque :

Nous avons exclu *diameter* et *whole weight* car ils sont fortement corrélés (corrélation proche de 1) avec d'autres variables.

3.3 Encodage de la variable catégorielle « sex »

```
X['sex.M'] = [1 if s == 'M' else 0 for s in X['sex']]
X['sex.F'] = [1 if s == 'F' else 0 for s in X['sex']]
X['sex.I'] = [1 if s == 'I' else 0 for s in X['sex']]
X = X.drop('sex', axis=1)

X.head()
```

On obtient ainsi un ensemble final de variables numériques prêtes pour l'apprentissage.

	length	height	shucked weight	viscera weight	shell weight	sex.M	sex.F	sex.I
0	0.455	0.095	0.2245	0.1010	0.150	1	0	0
1	0.350	0.090	0.0995	0.0485	0.070	1	0	0
2	0.530	0.135	0.2565	0.1415	0.210	0	1	0
3	0.440	0.125	0.2155	0.1140	0.155	1	0	0
4	0.330	0.080	0.0895	0.0395	0.055	0	0	1

4. Prétraitement

- Nous utilisons un **Random Forest Regressor** pour prédire le nombre d'anneaux.

```
model = RandomForestRegressor()
model.fit(X.to_numpy(), y)
```

Important :

La conversion en numpy array est nécessaire pour éviter des avertissements lors de la création des ALE.

5. Création des explications ALE

Nous utilisons la classe ALE d'Alibi et la fonction explain pour générer les effets locaux accumulés.

5.1 Initialisation de l'explainer ALE

```
ale = ALE(model.predict,  
          feature_names=X.columns,  
          target_names=['rings'])
```

5.2 Génération des explications

```
exp = ale.explain(X.to_numpy())
```

6. Visualisation des ALE

6.1 ALE pour les trois premières variables

```
plot_ale(exp, features=[0,1,2],  
         fig_kw={'figwidth':15, 'figheight': 5})
```


Cela affiche les ALE pour :

- **length**
- **height**
- **shucked weight**

6.2 Partie 1 : Interprétation des ALE individuels

1. En observant les ALE des variables **length**, **height** et **shucked weight**, quelle variable semble avoir l'**impact le plus important** sur le nombre d'anneaux prédits ? Justifiez votre réponse à partir du graphique.
2. Comment comparer l'effet de **length** et **height** par rapport à **shucked weight** sur la prédiction du modèle ?
3. Que signifie la **pente décroissante** observée pour la variable *shucked weight* ?
4. Le modèle est-il plus sensible aux variations de *length* ou de *shucked weight* ? Expliquez votre raisonnement.

7. Comprendre le centrage des ALE



Partie 2 : Compréhension du centrage des ALE (Figure 7)

5. Pourquoi les courbes ALE sont-elles **centrées autour de 0** ?
6. Que représente une valeur ALE positive ? Et une valeur négative ?
7. Comment interpréter un point ALE donné par rapport à la **prédiction moyenne** du modèle ?
8. En observant la valeur ALE pour *shucked weight* = 0, que peut-on dire de son effet sur le nombre d'anneaux prédits par rapport à la moyenne ?
9. Comparez l'effet de *shucked weight* = 0 et *shucked weight* = 1.4. Que peut-on en déduire ?

L'ALE est **centré sur 0**. Cela est fait en soustrayant la moyenne des effets locaux accumulés non centrés à chaque effet local accumulé non centré. Cela peut être déroutant au début. Pour trouver la moyenne de l'ALE, il faut d'abord sommer les effets locaux accumulés en chaque point du graphique.

Ainsi, chaque point d'un ALE représente l'effet de la valeur correspondante de la variable **par rapport à l'effet moyen de cette variable**, ou plus simplement, **par rapport à la prédiction moyenne**.

Les ALE sont **centrés autour de 0**.

Cela signifie que :

- Chaque valeur représente un **effet relatif par rapport à la prédiction moyenne**.
- Une valeur positive => augmentation de la prédiction par rapport à la moyenne.
- Une valeur négative => diminution de la prédiction.

Exemple (shucked weight) :

- Un *shucked weight* proche de 0 augmente la prédiction d'environ **6 anneaux** par rapport à la moyenne.
- Cette valeur est environ **12 anneaux plus élevée** que pour un poids de 1.4.

8. Combinaison de plusieurs ALE

Il est parfois utile de comparer plusieurs variables similaires sur le même graphique.

Exemple : variables de poids

```
fig, ax = plt.subplots(1, 1, figsize=(8, 4))

plot_ale(exp, features=[2], ax=ax, line_kw={'label': 'shucked weight'})
plot_ale(exp, features=[3], ax=ax, line_kw={'label': 'viscera weight'})
plot_ale(exp, features=[4], ax=ax, line_kw={'label': 'shell weight'})

ax.set_xlabel('weight')
```

Partie 3 : Combinaison de plusieurs ALE (Figure 8)

10. Pourquoi peut-il être utile de représenter plusieurs ALE sur un **même graphique** ?
11. En comparant les ALE de **shucked weight**, **viscera weight** et **shell weight**, quelles différences observe-t-on dans leurs effets sur la prédiction ?
12. Quelles variables ont un effet significatif sur la prédiction ? Comment le voyez-vous sur le graphique ?
13. Pourquoi deux variables fortement corrélées peuvent-elles avoir des effets **opposés** sur la prédiction du modèle ?
14. Que suggère ce comportement concernant la présence éventuelle **d'interactions entre variables** ?

9. Influence de la taille des intervalles (min_bin_points)

Par défaut, Alibi choisit des intervalles contenant **au moins 4 observations**. Dans les zones peu denses, cela crée des intervalles larges.

Augmentation du nombre minimum d'observations

```
ale = ALE(model.predict,  
          feature_names=X.columns,  
          target_names=['rings'])  
  
exp = ale.explain(X.to_numpy(), min_bin_points=50)
```

python

```
fig, ax = plt.subplots(1, 1, figsize=(8, 4))  
  
plot_ale(exp, features=[2], ax=ax, line_kw={'label': 'shucked weight'})  
plot_ale(exp, features=[3], ax=ax, line_kw={'label': 'viscera weight'})  
plot_ale(exp, features=[4], ax=ax, line_kw={'label': 'shell weight'})  
  
ax.set_xlabel('weight')
```

Partie 4 : Taille des intervalles et densité des données

15. Pourquoi observe-t-on des **intervalles de tailles différentes** dans les graphiques ALE ?
16. Quel est le rôle du paramètre `min_bin_points` dans la construction des ALE ?
17. Pourquoi les intervalles deviennent-ils plus larges dans les zones où les données sont peu nombreuses ?

Partie 5 : Effet de l'augmentation de `min_bin_points` (Figure 9)

18. Quelles différences observez-vous entre les graphiques ALE obtenus avec `min_bin_points = 4` et `min_bin_points = 50` ?
19. Comment l'augmentation de `min_bin_points` affecte-t-elle la **lissage** des courbes ALE ?
20. Quels sont les avantages et les inconvénients de l'utilisation de grands intervalles ?

Partie 6 : Discussion générale

21. Pourquoi est-il recommandé de se concentrer sur la **tendance globale** des ALE plutôt que sur les variations locales ?
22. En quoi l'interprétation des ALE est-elle plus complexe que celle des **PDP (Partial Dependence Plots)** ?

23. Pourquoi est-il pertinent d'utiliser à la fois **ALE et PDP** lors de l'analyse d'un modèle ?
24. Dans quel cas privilégieriez-vous la présentation des PDP plutôt que des ALE ?