

TP3 : Interprétabilité des modèles avec SHAP-Partie1-

Objectifs du TP

À la fin de ce TP, vous sera capable de :

- Comprendre le principe de SHAP (SHapley Additive exPlanations)
- Appliquer SHAP sur des **données tabulaires**, des **images**, du **texte** et des **modèles génératifs**
- Analyser des **biais potentiels** (âge, sexe, relation, etc.)
- Comparer SHAP avec des méthodes globales comme **PDP** et **ALE**
- Interpréter des explications **locales** (instance individuelle) et **globales** (ensemble de données)

Partie 1 : SHAP sur données tabulaires (Adult Dataset)

1.1 Chargement des bibliothèques

```
import pickle
import warnings
from pprint import pprint

import xgboost as xgb
import matplotlib.pyplot as plt
import numpy as np
from sklearn.model_selection import StratifiedKFold, train_test_split

import shap
shap.initjs()
```

Explication :

- `xgboost` : modèle non linéaire basé sur des arbres
- `shap` : bibliothèque d'interprétabilité basée sur la théorie des jeux
- `shap.initjs()` : permet l'affichage interactif des visualisations

1.2 Chargement du jeu de données Adult

```
X, y = shap.datasets.adult()
X_display, y_display = shap.datasets.adult(display=True)
```

Le jeu de données *Adult* vise à prédire si le revenu d'une personne dépasse 50K\$ en fonction de variables socio-démographiques (âge, sexe, éducation, relation, etc.).

1.3 Séparation Train / Test

80 % des données sont utilisées pour l'apprentissage et 20 % pour le test.

```
# create a train/test split

random_state = 7
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=random_state
)
```

1.4 Entraînement du modèle

Nous utilisons un modèle **XGBoost**, puissant mais peu interprétable sans méthodes XAI.

```
model = xgb.XGBClassifier()
model.fit(X_train, y_train)
```

Explication importante :

- Même si XGBoost dispose de `TreeExplainer`, nous utilisons ici « **Permutation Explainer** »
- Avantage : sortie générique, cohérente pour tous les types de modèles

Partie 2 : Calcul des valeurs SHAP

2.1 Principe théorique de SHAP

SHAP (SHapley Additive exPlanations) est une méthode d'interprétabilité basée sur la **théorie des jeux coopératifs**.

⇒ Chaque variable est vue comme un *joueur* qui contribue à la prédiction finale du modèle.

La prédiction d'un modèle pour une instance donnée est décomposée comme suit :

$$f(x) = E[f(x)] + \text{somme des contributions SHAP}$$

Où :

- $E[f(x)]$: valeur moyenne du modèle (baseline)
- contribution SHAP : impact individuel de chaque variable

⇒ Une valeur SHAP positive **augmente** la prédiction, une valeur négative la **diminue**.

2.2. Calcul des valeurs SHAP


```
explainer = shap.Explainer(lambda x: model.predict_proba(x)[:, 1], X)
shap_values = explainer(X[:1000])
```

- On explique la probabilité de la classe « revenu > 50K »
- Le Permutation Explainer mesure l'impact réel de chaque variable
- Le calcul est coûteux, d'où la limitation à 1000 instances

Partie 3 : Analyse de biais et visualisations

3.1 Scatter plot : Âge

```
feature_names = list(X.columns)
shap.plots.scatter(shap_values[:, feature_names.index("Age")],
color=shap_values)
```



Question :

- L'âge influence-t-il positivement ou négativement le revenu ?
- Observe-t-on une rupture ou un seuil critique ?

3.2 Analyse croisée : Age vs Sex

```
shap.plots.scatter(shap_values[:, 'Age'], color=shap_values[:, 'Sex'])
```

3.3 Relationship vs Sex

```
shap.plots.scatter(shap_values[:, 'Relationship'], color=shap_values[:, 'Sex'])
```

Questions (biais) :

- Les hommes et les femmes sont-ils traités de la même manière par le modèle ?
- Retrouve-t-on des **symptômes de biais** ?

3.4 Comparaison avec PDP et ALE

Questions :

- Les tendances observées avec SHAP sont-elles similaires à celles des PDP ?
- ALE permet-il de mieux gérer les variables corrélées ?

Répéter la comparaison pour :

- un modèle **linéaire additif** (régression logistique)
- un modèle **non linéaire** (XGBoost)

Partie 4 : Explications locales

4.1 Force plot (instance unique)

```
shap.plots.force(shap_values[0])
```

Questions :

- Quelles variables poussent la prédiction vers un revenu élevé ?
- Quelles variables ont un impact négatif ?

4.2 Decision plot (toutes les instances)

```
shap.plots.decision(shap_values)
```

Comparaison :

- Différence entre explication locale (force plot) et globale (decision plot)

Partie 5 : SHAP pour les images (ResNet50)

5.1 Chargement du modèle et des données

```
import tensorflow as tf
from tensorflow.keras.applications.resnet50 import ResNet50, preprocess_input

model = ResNet50(weights='imagenet')
X, y = shap.datasets.imagenet50()
```

5.2 Définition du prédicteur


```
def predict(x):
    tmp = x.copy()
    preprocess_input(tmp)
    return model(tmp)
```

5.3 Masker et expliquer

```
masker = shap.maskers.Image('blur(128,128)', shape=X[0].shape)
explainer = shap.Explainer(predict, masker)
```

5.4 Visualisation

```
shap.image_plot(shap_values, pixel_values=X[index]/255)
```



Interprétation :

- Quelles régions de l'image influencent le plus la prédiction ?

Partie 6 : SHAP pour le texte


6.1 Analyse par sous-mots

```
from transformers import pipeline
model = pipeline('sentiment-analysis', return_all_scores=True)
s = ['This product was a scam']
print(model(s)[0][1])
```

6.2 Analyse par mots

```
import shap

masker = shap.maskers.Text(tokenizer=r"\W+")
explainer = shap.Explainer(model, masker)
shap_values = explainer(s)
shap.plots.bar(shap_values[0, :, 'POSITIVE'])
```




Question :

- Quels mots contribuent le plus au sentiment négatif ?

6.3 Analyse par phrases

```

s2 = "This product was a scam." + \
    "It was more about marketing than technology." + \
    "But that's why I loved it." + \
    "Learned a bunch about marketing that way."
masker = shap.maskers.Text(tokenizer=r"\.", mask_token=" ")
explainer = shap.Explainer(model, masker=masker)
shap_values = explainer([s2])
print("expected: %.2f" % shap_values.base_values[0][1])
print("prediction: %.2f" % model(s2)[0][1]['score'])
shap.plots.bar(shap_values[0, :, 'POSITIVE'])
    
```



Observation :

Analyse de l'impact de chaque phrase sur la prédiction globale.

Partie 7 : SHAP pour les modèles génératifs

- SHAP fournit des explications **locales et globales cohérentes**
- Applicable à tout type de données et de modèles
- Outil puissant pour l'analyse de biais et la confiance dans les modèles

Travail demandé :

1. Répondre aux questions d'analyse dans chaque section
2. Comparer SHAP avec PDP et ALE
3. Discuter des biais observés